

UNIVERSITETI I TETOVËS

FAKULTETI I SHKENCAVE MATEMATIKO NATYRORE

Departamenti i Informatikës



PUNIM DIPLOME

“Shpjegueshmëria dhe siguria në Machine Learning: Një analizë krahasuese e SHAP dhe LIME përmes një platforme interaktive web”

MENTOR:

Prof.Dr. Florim Idrizi

KANDIDATI:

Remzije Sulejmanoska

Tetovë, 2026

MENTOR:

Prof.Dr. Florim Idrizi,

Fakulteti i Shkencave Matematike-Natyrore,
Universiteti I Tetovës

ANËTARËT E KOMISIONIT:

Prof.Dr. Florim Idrizi,

Dekan, Profesor inordinar (*mentor*),
Fakulteti i Shkencave Matematike-
Natyrore, Universiteti i Tetovës

..

Titulli i fituar: Inxhinier i diplomuar i Informatikës

Data e mbrojtjes:

Dega: Informatikë

Programi Studimor: Infromatikë Profesional

FALËNDERIMET

Me rastin e diplomimit tim, dëshiroj të shpreh mirënjohjen time të singertë ndaj të gjithë atyre që më kanë mbështetur gjatë këtij rrugëtimi akademik.

Në veçanti, falënderoj mentorin tim, **Prof. Dr. Florim Idrizin**, për udhëzimin profesional, këshillat e vlefshme, durimin dhe mbështetjen e vazhdueshme gjatë realizimit të këtij punimi. Njohuritë, përkushtimi dhe sugjerimet e tij kanë qenë një ndihmë e madhe në çdo fazë të hulumtimit dhe zhvillimit të këtij projekti. Bashkëpunimi me të ka qenë një përvojë shumë e vlefshme për zhvillimin tim akademik dhe profesional.

Një falënderim i veçantë i takon familjes sime, veçanërisht prindërve të mi, të cilët kanë qenë mbështetja ime më e madhe gjatë gjithë studimeve. Sakrificat, përkrahja e pakushtëzuar, besimi dhe inkurajimi i tyre më kanë motivuar të vazhdoj përpara edhe në momentet më sfiduese. Pa dashurinë dhe përkushtimin e tyre, arritja e këtij suksesi do të ishte shumë më e vështirë.

Gjithashtu, shpreh mirënjohjen time ndaj të afërmeve dhe miqve të mi, të cilët më kanë mbështetur me fjalë inkurajuese, motivim dhe mirëkuptim gjatë periudhës së studimeve dhe realizimit të këtij punimi. Mbështetja e tyre ka pasur një rol të rëndësishëm në ruajtjen e motivimit dhe përkushtimit tim drejt arritjes së objektivave akademike.

Në fund, falënderoj Universitetin e Tetovës dhe stafin akademik të Fakultetit të Shkencave Matematiko-Natyrore për njohuritë e fituara gjatë viteve të studimit, të cilat kanë kontribuar në formimin tim profesional dhe personal.

Të gjithëve ju shpreh respektin dhe mirënjohjen time më të thellë për kontributin dhe mbështetjen që më keni dhënë gjatë këtij rrugëtimi të rëndësishëm në jetën time.

PËRMBAJTJA

1. Hyrje	6
1.1 Problemi i interpretueshmërisë në Machine Learning	7
1.2 Rëndësia e Explainable AI në sistemet moderne	8
1.3 Motivimi i punimit	9
1.4 Qëllimet dhe objektivat e hulumtimit	10
1.5 Struktura e punimit	11
2. Bazat Teorike dhe Literatura.....	13
2.1 Konceptet themelore të Machine Learning.....	13
2.2 Modelet “Black Box” dhe sfidat e interpretueshmërisë.....	14
2.3 Explainable Artificial Intelligence (XAI)	16
2.4 Siguria dhe besueshmëria në sistemet inteligjente.....	17
2.5 Analiza e punimeve ekzistuese mbi SHAP dhe LIME	18
3. Metodat e Shpjegueshmërisë në Machine Learning	20
3.1 Metoda SHAP	20
3.1.1 Bazat teorike të SHAP	20
3.1.2 Shapley Values dhe interpretimi i rezultateve	22
3.1.3 Avantazhet dhe kufizimet e SHAP	23
3.2 Metoda LIME.....	23
3.2.1 Bazat teorike të LIME.....	23
3.2.2 Interpretimi lokal i modeleve.....	24
3.2.3 Avantazhet dhe kufizimet e LIME.....	25
3.3 Krahasimi teorik ndërmjet SHAP dhe LIME.....	26
4. Metodologjia dhe Arkitektura e Sistemit	29
4.1 Përshkrimi i dataset-it	29
4.2 Përpunimi dhe përgatitja e të dhënave	29

4.3 Zgjedhja dhe trajnimi i modelit Machine Learning	30
4.4 Integrimi i SHAP dhe LIME në sistem.....	31
4.4.1 Integrimi teknik i SHAP	31
4.4.2 Integrimi teknik i LIME.....	35
4.4.3 Krahasimi i para-vërejtjeve nga integrimi.....	36
4.5 Arkitektura e platformës interaktive web.....	36
4.6 Teknologjitë dhe mjetet e përdorura	37
5. Implementimi i platformës interaktive Web	39
5.1 Dizajni i sistemit	39
5.1.1 Struktura modulare e shtatë faqeve	39
5.1.2 Identiteti vizual dhe parimet e dizajnit.....	40
5.2 Implementimi i backend-it.....	41
5.2.1 Ngarkimi i modelit në momentin e nisjes	41
5.2.2 Struktura e endpoint-eve API.....	42
5.2.3 Transmetimi i grafikëve: nga Matplotlib te browser.....	43
5.3 Implementimi i ndërfaqes së përdoruesit	43
5.3.1 Komunikimi asinkron me backend-in.....	44
5.3.2 Navigimi pa rifreskim faqeje	44
5.3.3 Rrjedha e plotë e ndërveprimit të përdoruesit	45
5.4 Gjenerimi i parashikimeve të modelit.....	46
5.5 Vizualizimi i rezultateve të SHAP	47
5.5.1 Niveli global - sjellja e modelit në shkallë të gjerë	47
5.5.2 Niveli lokal - Waterfall Plot për studentin specifik	48
5.6 Vizualizimi i rezultateve të LIME	50
5.6.1 Rikrijimi i explainer-it dhe gjenerimi i shpjegimit	50
5.6.2 Krahasimi i formatit të shpjegimit me SHAP	50
5.7 Funksionalitetet interaktive të platformës.....	52

5.7.1 Krahاسimi automatik SHAP vs LIME	52
5.7.2 Analiza e privatësisë si veçori e integruar.....	53
5.7.3 Përvoja e përdoruesit dhe optimizimet e performancës	54
6. Rezultatet eksperimentale dhe analiza krahasuese.....	55
6.1 Metrikat e vlerësimit të modelit	55
6.2 Analiza e performancës së modelit	56
6.3 Krahاسimi i rezultateve të SHAP dhe LIME.....	57
6.3.1 Tabela krahasuese e vlerave.....	57
6.3.2 Konvergjenca: ku bien dakord SHAP dhe LIME	58
6.3.3 Divergjenca: ku ndryshojnë në magnitudë.....	58
6.4 Analiza e interpretueshmërisë	59
6.4.1 Format i shpjegimit dhe audienca e synuar.....	59
6.4.2 Testimi i stabilitetit të LIME.....	60
6.5 Analiza e sigurisë dhe besueshmërisë	60
6.5.1 Feature Risk Score - rreziku i ekspozimit sipas veçorisë.....	60
6.5.2 Membership Inference Attack - a mund të zbulohet nëse një student ishte në dataset-in e trajnimit?	61
6.6 Diskutimi i rezultateve	62
6.6.1 Sa 'transparent' bëhet vërtet modeli?.....	62
6.6.2 Tensioni transparencë–privatësi: a është i pashmangshëm?	63
6.6.3 Vlera krahasuese e platformës si instrument kërkimor	63
7. Përfundime dhe punë e ardhshme	64
7.1 Përfundimet kryesore	64
7.2 Kontributet e punimit	65
7.2.1 Kontributi teknik - platforma XAI Explorer	65
7.2.2 Kontributi analitik - krahاسimi sasior i drejtpërdrejtë	65
7.2.3 Kontributi konceptual - lidhja empirike mes shpjegueshmërisë dhe privatësisë	65

7.3 Kufizimet e studimit	66
7.4 Drejtime për hulumtime të ardhshme.....	66
LITERATURA	69

1. Hyrje

Në dekadat e fundit, zhvillimi i teknologjive të Inteligjencës Artificiale dhe Machine Learning ka transformuar mënyrën se si analizohen të dhënat dhe merren vendime në shumë fusha të jetës së përditshme. Këto teknologji përdoren gjerësisht në sektorë të ndryshëm, si shëndetësia, financat, arsimi, transporti, siguria kibernetike dhe tregtia elektronike, duke ofruar zgjidhje efikase për probleme komplekse dhe duke mundësuar automatizimin e proceseve që më parë kërkonin ndërhyrje të konsiderueshme njerëzore.

Modelet moderne të Machine Learning janë në gjendje të përpunojnë sasi të mëdha të dhënash dhe të identifikojnë modele të fshehura me një saktësi të lartë. Për shkak të performancës së tyre të avancuar, këto modele po bëhen gjithnjë e më të rëndësishme në proceset e vendimmarrjes. Megjithatë, rritja e kompleksitetit të modeleve ka sjellë edhe sfida të reja, veçanërisht në aspektin e transparencës dhe interpretueshmërisë së rezultateve që ato gjenerojnë.

Shumë nga algoritmet më të fuqishme të Machine Learning funksionojnë si sisteme të mbyllura, ku përdoruesi mund të shohë rezultatin përfundimtar, por jo arsyet konkrete që kanë ndikuar në atë vendim. Kjo situatë krijon vështirësi në vlerësimin e besueshmërisë së sistemit, veçanërisht në aplikacione ku vendimet kanë ndikim të drejtpërdrejtë tek individët ose organizatat. Për këtë arsye, gjatë viteve të fundit është rritur interesimi për zhvillimin e metodave që mundësojnë shpjegimin dhe interpretimin e vendimeve të modeleve të inteligjencës artificiale.

Explainable Artificial Intelligence (XAI) paraqet një nga drejtimet më të rëndësishme të kërkimit në fushën e inteligjencës artificiale, duke synuar rritjen e transparencës, besueshmërisë dhe kuptueshmërisë së modeleve. Përmes teknikave të ndryshme të shpjegueshmërisë, përdoruesit mund të kuptojnë faktorët që ndikojnë në parashikimet e modelit dhe të vlerësojnë nëse vendimet e marra janë logjike, të drejta dhe të besueshme.

Në këtë kontekst, ky punim fokusohet në analizimin dhe krahasimin e dy metodave më të njohura të Explainable Artificial Intelligence, SHAP (SHapley Additive Explanations) dhe LIME (Local Interpretable Model-Agnostic Explanations). Përveç analizës teorike, është zhvilluar edhe një platformë interaktive web që mundëson vizualizimin e rezultateve dhe krahasimin praktik të këtyre metodave në një model të Machine Learning. Përmes kësaj qasjeje synohet të vlerësohet ndikimi i SHAP dhe LIME në përmirësimin e interpretueshmërisë, sigurisë dhe besueshmërisë së sistemeve inteligjente.

1.1 Problemi i interpretueshmërisë në Machine Learning

Machine Learning ka sjellë përparime të jashtëzakonshme në analizimin e të dhënave dhe automatizimin e proceseve vendimmarrëse. Falë aftësisë për të mësuar nga të dhënat historike dhe për të identifikuar modele komplekse, algoritmet e Machine Learning përdoren sot në shumë fusha ku kërkohet saktësi dhe efikasitet i lartë. Megjithatë, ndërsa performanca e modeleve është përmirësuar vazhdimisht, është shfaqur një problem i rëndësishëm që lidhet me mënyrën se si këto modele marrin vendime. Shumë modele moderne, veçanërisht ato të bazuara në rrjete nervore të thella (Deep Neural Networks), ensemble methods dhe algoritme të tjera komplekse, konsiderohen si modele "Black Box". Ky term përdoret për të përshkruar sisteme që prodhojnë rezultate të sakta, por procesi i brendshëm që çon në këto rezultate mbetet i vështirë ose i pamundur për t'u kuptuar nga përdoruesit. Në praktikë, kjo do të thotë se modeli mund të japë një parashikim ose rekomandim, por nuk ofron informacion të mjaftueshëm për të shpjeguar pse është marrë pikërisht ai vendim.

Mungesa e interpretueshmërisë paraqet një sfidë serioze në shumë aplikacione reale. Për shembull, në sektorin e shëndetësisë, një model mund të parashikojë praninë e një sëmundjeje tek një pacient, por mjekët kanë nevojë të kuptojnë faktorët që kanë ndikuar në atë parashikim përpara se të marrin vendime klinike. Në sektorin financiar, institucionet bankare përdorin modele të Machine Learning për vlerësimin e kredive, por klientët dhe ekspertët financiarë kërkojnë transparencë mbi arsyet e pranimin ose refuzimit të një aplikimi. Situata të ngjashme hasen edhe në sistemet e sigurisë, rekrutimit, arsimit dhe shumë fusha të tjera ku vendimet e automatizuara mund të kenë pasoja të rëndësishme.

Një problem tjetër lidhet me besimin e përdoruesve ndaj sistemeve inteligjente. Nëse përdoruesit nuk kuptojnë mënyrën se si një model arrin në një përfundim të caktuar, ata mund të hezitojnë ta përdorin ose të mbështeten tek rezultatet e tij. Për më tepër, mungesa e transparencës e bën më të vështirë identifikimin e gabimeve, paragjykimeve (bias) dhe dobësive të mundshme që mund të ekzistojnë në model ose në të dhënat e përdorura për trajnim.

Interpretueshmëria luan gjithashtu një rol të rëndësishëm në aspektin e sigurisë dhe besueshmërisë së sistemeve të inteligjencës artificiale. Një model që mund të shpjegojë vendimet e tij lejon monitorim më të mirë, identifikim më të shpejtë të anomalive dhe verifikim të korrektësisë së rezultateve. Kjo është veçanërisht e rëndësishme në sistemet ku kërkohet përgjegjësi dhe transparencë në procesin e vendimmarrjes.

Për të adresuar këto sfida, komuniteti shkencor ka zhvilluar metoda dhe teknika të ndryshme të Explainable Artificial Intelligence (XAI), të cilat synojnë të bëjnë modelet e Machine Learning më të

kuptueshme për përdoruesit. Këto metoda mundësojnë analizimin e faktorëve që ndikojnë në vendimet e modelit dhe ofrojnë shpjegime të interpretuara në mënyrë të qartë. Ndër metodat më të njohura dhe më të përdorura janë SHAP (SHapley Additive Explanations) dhe LIME (Local Interpretable Model-Agnostic Explanations), të cilat do të analizohen dhe krahasohen në detaje në këtë punim.

1.2 Rëndësia e Explainable AI në sistemet moderne

Me rritjen e përdorimit të Inteligjencës Artificiale në proceset e përditshme të vendimmarrjes, nevoja për transparencë dhe kuptueshmëri të modeleve është bërë gjithnjë e më e rëndësishme. Organizatat dhe përdoruesit nuk kërkojnë vetëm rezultate të sakta, por edhe shpjegime të qarta mbi mënyrën se si janë arritur ato rezultate. Në këtë kontekst, Explainable Artificial Intelligence (XAI) është shfaqur si një fushë e rëndësishme kërkimore që synon të bëjë sistemet inteligjente më transparente, më të besueshme dhe më të kuptueshme.

Një nga përfitimet kryesore të Explainable AI është rritja e besimit të përdoruesve ndaj sistemeve të inteligjencës artificiale. Kur një model ofron shpjegime të qarta për vendimet e tij, përdoruesit kanë më shumë mundësi të kuptojnë logjikën që qëndron pas parashikimeve dhe të ndihen më të sigurt në përdorimin e sistemit. Kjo është veçanërisht e rëndësishme në aplikacionet ku vendimet e modelit mund të ndikojnë drejtpërdrejt në jetën e individëve, si në mjekësi, financa apo administratë publike.

Një aspekt tjetër i rëndësishëm është identifikimi dhe reduktimi i paragjyqimeve në modelet e Machine Learning. Modelet trajnohen mbi të dhëna historike dhe, nëse këto të dhëna përmbajnë paragjyqime ose pabarazi, modeli mund t'i trashëgojë dhe t'i përforcojë ato gjatë procesit të vendimmarrjes. Metodat e Explainable AI ndihmojnë në identifikimin e faktorëve që ndikojnë në rezultatet e modelit dhe mundësojnë zbulimin e sjelljeve të padëshiruara ose diskriminuese. Kjo kontribuon në zhvillimin e sistemeve më të drejta dhe më etike.

Explainable AI luan gjithashtu një rol të rëndësishëm në sigurinë dhe besueshmërinë e sistemeve inteligjente. Kur vendimet e modelit mund të analizohen dhe interpretohen, bëhet më e lehtë të identifikohen gabimet, anomalitë dhe dobësitë e mundshme. Kjo u mundëson zhvilluesve dhe ekspertëve të ndërmarrin masa korrigjuese për përmirësimin e performancës dhe sigurisë së sistemit. Për më tepër, interpretueshmëria ndihmon në verifikimin e korrektesisë së rezultateve dhe në monitorimin e sjelljes së modelit gjatë përdorimit në mjedise reale.

Në vitet e fundit është rritur edhe rëndësia e aspektit ligjor dhe rregullator të inteligjencës artificiale. Organizata dhe institucione të ndryshme po kërkojnë që sistemet e bazuara në AI të jenë transparente dhe të ofrojnë mundësi për shpjegimin e vendimeve automatike. Kjo është veçanërisht e rëndësishme në sektorë ku vendimet duhet të jenë të justifikueshme dhe të auditueshme. Për këtë arsye, interpretueshmëria nuk konsiderohet më vetëm një veçori shtesë, por një kërkesë e rëndësishme për zhvillimin dhe përdorimin e përgjegjshëm të inteligjencës artificiale.

Përveç përfitimeve teknike, Explainable AI ndihmon edhe në krijimin e një bashkëpunimi më efektiv ndërmjet njerëzve dhe sistemeve inteligjente. Kur përdoruesit kuptojnë mënyrën se si funksionon modeli dhe cilët faktorë ndikojnë në vendimet e tij, ata mund të marrin vendime më të informuara dhe të përdorin teknologjinë me më shumë siguri. Kjo e bën Explainable AI një komponent të domosdoshëm në zhvillimin e sistemeve moderne të Machine Learning.

Duke marrë parasysh këto përfitime, metodat e Explainable AI, si SHAP dhe LIME, kanë fituar vëmendje të madhe në komunitetin shkencor dhe industrial. Këto metoda ofrojnë mekanizma të ndryshëm për interpretimin e modeleve komplekse dhe ndihmojnë në rritjen e transparencës, besueshmërisë dhe pranueshmërisë së inteligjencës artificiale në aplikime reale.

1.3 Motivimi i punimit

Zhvillimi i shpejtë i modeleve të Machine Learning ka sjellë përmirësime të konsiderueshme në saktësinë e parashikimeve dhe në automatizimin e proceseve të ndryshme. Megjithatë, pavarësisht performancës së lartë që ofrojnë këto modele, transparenca dhe interpretueshmëria e tyre mbeten ndër sfidat më të mëdha në përdorimin praktik të inteligjencës artificiale. Në shumë raste, përdoruesit dhe organizatat përballen me rezultate të sakta, por pa pasur një kuptim të qartë mbi arsyet që kanë çuar në ato rezultate.

Motivimi për realizimin e këtij punimi buron nga rëndësia gjithnjë në rritje e Explainable Artificial Intelligence (XAI) dhe nevoja për të kuptuar më mirë mënyrën se si modellet e Machine Learning marrin vendime. Gjatë studimit të fushës së inteligjencës artificiale, është vërejtur se një nga problemet kryesore nuk lidhet vetëm me performancën e modelit, por edhe me aftësinë për të shpjeguar dhe justifikuar rezultatet e tij. Kjo çështje bëhet edhe më e rëndësishme në aplikime ku vendimet e sistemit mund të kenë ndikim të drejtpërdrejtë tek individët ose organizatat.

Një arsye tjetër që ka motivuar këtë hulumtim është interesi për të analizuar dy nga metodat më të njohura të Explainable AI, SHAP dhe LIME, të cilat përdoren gjerësisht për interpretimin e modeleve komplekse. Edhe pse të dyja metodat synojnë të ofrojnë shpjegime për vendimet e modelit, ato bazohen në qasje të ndryshme dhe mund të prodhojnë rezultate të ndryshme në situata të ndryshme. Për këtë arsye, është e rëndësishme të analizohet mënyra e funksionimit të tyre, avantazhet, kufizimet dhe ndikimi që kanë në rritjen e transparencës së sistemeve inteligjente.

Për të realizuar një analizë më praktike dhe më të kuptueshme, në kuadër të këtij punimi është zhvilluar një platformë interaktive web që mundëson integrimin e modelit të Machine Learning me metodat SHAP dhe LIME. Platforma lejon gjenerimin e parashikimeve dhe vizualizimin e shpjegimeve të ofruara nga secila metodë, duke krijuar mundësi për krahasim të drejtpërdrejtë të rezultateve. Kjo qasje praktike ndihmon në kuptimin më të mirë të sjelljes së modelit dhe të rolit që luajnë metodat e shpjegueshmërisë në interpretimin e rezultateve.

Gjithashtu, ky punim synon të kontribuojë në rritjen e ndërgjegjësimit mbi rëndësinë e transparencës dhe besueshmërisë në sistemet e inteligjencës artificiale. Duke analizuar në mënyrë teorike dhe praktike metodat SHAP dhe LIME, synohet të ofrohet një pasqyrë më e qartë mbi përdorimin e tyre dhe mbi përfitimet që ato sjellin në zhvillimin e sistemeve inteligjente më të kuptueshme dhe më të besueshme.

Në këtë mënyrë, motivimi kryesor i këtij punimi është kombinimi i aspektit teorik me atë praktik për të analizuar dhe krahasuar dy nga metodat më të rëndësishme të Explainable AI, duke vlerësuar kontributin e tyre në përmirësimin e interpretueshmërisë, sigurisë dhe besueshmërisë së modeleve të Machine Learning.

1.4 Qëllimet dhe objektivat e hulumtimit

Qëllimi kryesor i këtij punimi është të analizojë dhe të krahasojë metodat SHAP (SHapley Additive Explanations) dhe LIME (Local Interpretable Model-Agnostic Explanations) në aspektin e interpretueshmërisë së modeleve të Machine Learning, si dhe të vlerësojë ndikimin e tyre në rritjen e transparencës, sigurisë dhe besueshmërisë së sistemeve inteligjente.

Me rritjen e përdorimit të inteligjencës artificiale në fusha të ndryshme, nevoja për të kuptuar procesin e vendimmarrjes së modeleve është bërë gjithnjë e më e rëndësishme. Për këtë arsye, ky hulumtim fokusohet në studimin e teknikave të Explainable Artificial Intelligence dhe në analizimin e aftësisë së tyre për të ofruar shpjegime të qarta dhe të kuptueshme për përdoruesit.

Për realizimin e qëllimit kryesor janë përcaktuar disa objektiva specifike:

- Studimi i koncepteve themelore të Machine Learning dhe Explainable Artificial Intelligence (XAI).
- Analizimi i problemit të interpretueshmërisë në modelet moderne të Machine Learning.
- Hulumtimi i bazave teorike, karakteristikave dhe mënyrës së funksionimit të metodave SHAP dhe LIME.
- Identifikimi i avantazheve dhe kufizimeve të secilës metodë në interpretimin e modeleve komplekse.
- Zhvillimi i një platforme interaktive web për gjenerimin e parashikimeve dhe vizualizimin e rezultateve të shpjegueshmërisë.
- Integrimi i metodave SHAP dhe LIME në platformën e zhvilluar.
- Kryerja e analizave eksperimentale për të vlerësuar performancën dhe interpretueshmërinë e metodave të përzgjedhura.
- Krahasimi i rezultateve të gjeneruara nga SHAP dhe LIME nëpërmjet shembujve praktikë.

Vlerësimi i ndikimit të këtyre metodave në rritjen e transparencës, besueshmërisë dhe sigurisë së sistemeve të bazuara në inteligjencë artificiale.

Përmes arritjes së këtyre objektivave, punimi synon të ofrojë një analizë të detajuar të metodave SHAP dhe LIME, si dhe të demonstrojë rëndësinë e tyre në interpretimin e modeleve të Machine Learning. Gjithashtu, rezultatet e këtij hulumtimi pritet të kontribuojnë në kuptimin më të mirë të rolit që luan Explainable AI në zhvillimin e sistemeve inteligjente moderne dhe në rritjen e besimit të përdoruesve ndaj vendimeve të gjeneruara nga këto sisteme.

1.5 Struktura e punimit

Për të siguruar një trajtim të organizuar dhe të qartë të temës së hulumtimit, ky punim është ndarë në shtatë kapituj kryesorë, të cilët mbulojnë aspektet teorike, metodologjike dhe praktike të analizës së metodave SHAP dhe LIME në interpretimin e modeleve të Machine Learning.

Kapitulli i parë paraqet hyrjen e përgjithshme të punimit. Në këtë kapitull trajtohet problemi i interpretueshmërisë në Machine Learning, rëndësia e Explainable Artificial Intelligence në sistemet moderne, motivimi i zgjedhjes së temës, qëllimet dhe objektivat e hulumtimit, si dhe struktura e përgjithshme e punimit.

Kapitulli i dytë fokusohet në bazat teorike dhe literaturën ekzistuese. Në këtë pjesë prezantohen konceptet themelore të Machine Learning, karakteristikat e modeleve “Black Box”, koncepti i Explainable Artificial Intelligence (XAI), si dhe rëndësia e sigorisë dhe besueshmërisë në sistemet inteligjente. Gjithashtu, realizohet një analizë e studimeve dhe punimeve shkencore që trajtojnë metodat SHAP dhe LIME.

Kapitulli i tretë trajton metodat e shpjegueshmërisë në Machine Learning. Fillimisht prezantohet metoda SHAP, bazat e saj teorike, koncepti i Shapley Values dhe mënyra e interpretimit të rezultateve. Më pas analizohet metoda LIME, funksionimi i saj dhe qasja që përdor për interpretimin lokal të modeleve. Në fund të kapitullit realizohet një krahasim teorik ndërmjet dy metodave.

Kapitulli i katërt përshkruan metodologjinë e përdorur në hulumtim dhe arkitekturën e sistemit të zhvilluar. Në këtë kapitull paraqiten të dhënat e përdorura, procesi i përgatitjes dhe përpunimit të tyre, zgjedhja dhe trajnimi i modelit të Machine Learning, integrimi i metodave SHAP dhe LIME, si dhe teknologjitë dhe mjetet e përdorura për zhvillimin e platformës.

Kapitulli i pestë fokusohet në implementimin e platformës interaktive web. Përshkruhen komponentët kryesorë të sistemit, implementimi i backend-it dhe ndërfaqes së përdoruesit, procesi i gjenerimit të parashikimeve dhe mënyra e vizualizimit të rezultateve të SHAP dhe LIME. Gjithashtu prezantohen funksionalitetet kryesore të platformës dhe ndërveprimi i përdoruesit me sistemin.

Kapitulli i gjashtë paraqet rezultatet eksperimentale dhe analizën krahasuese. Në këtë pjesë vlerësohet performanca e modelit të Machine Learning, analizohen rezultatet e gjeneruara nga SHAP dhe LIME, si dhe krahasohen aftësitë e tyre në interpretimin e vendimeve të modelit. Gjithashtu diskutohet ndikimi i tyre në aspektin e sigorisë, transparencës dhe besueshmërisë së sistemit.

Kapitulli i shtatë përmban përfundimet e punimit. Në këtë kapitull përmbledhen rezultatet kryesore të hulumtimit, paraqiten kontributet e realizuara, diskutohen kufizimet e studimit dhe jepen rekomandime për hulumtime dhe zhvillime të ardhshme në fushën e Explainable Artificial Intelligence.

Përmes kësaj strukture synohet të ofrohet një trajtim i plotë dhe sistematik i problematikës së interpretueshmërisë në Machine Learning, duke kombinuar analizën teorike me implementimin praktik dhe vlerësimin eksperimental të metodave SHAP dhe LIME.

2. Bazat Teorike dhe Literatura

2.1 Konceptet themelore të Machine Learning

Machine Learning është një degë e inteligjencës artificiale që fokusohet në zhvillimin e algoritmeve dhe modeleve që mund të mësojnë nga të dhënat pa u programuar në mënyrë eksplicite për çdo rregull. Në vend që të ndiqen udhëzime fikse të programuara nga njeriu, sistemet e Machine Learning analizojnë të dhëna historike dhe identifikojnë modele, lidhje dhe struktura që më pas përdoren për të bërë parashikime ose vendime mbi të dhëna të reja.

Në thelb, një sistem Machine Learning përbëhet nga tre komponentë kryesorë: të dhënat (dataset-i), modeli dhe procesi i trajnimit. Dataset-i përfaqëson informacionin mbi të cilin trajnohet modeli dhe mund të jetë i strukturuar (si tabela me rreshta dhe kolona) ose i pastrukturuar (si tekst, imazhe apo audio). Cilësia dhe sasia e të dhënave luajnë një rol shumë të rëndësishëm në performancën përfundimtare të modelit, pasi modeli mëson direkt nga këto të dhëna.




Figura 2.1: Modeli Machine Learning

Modeli është përfaqësimi matematikor i marrëdhënieve midis variablave hyrëse (features) dhe rezultatit dalës (label ose target). Gjatë procesit të trajnimit, modeli përpiqet të minimizojë gabimin midis parashikimeve të tij dhe rezultateve reale, duke përshtatur parametrat e brendshëm. Ky proces përsëritet disa herë derisa modeli të arrijë një nivel të pranueshëm saktësie.

Në Machine Learning, të dhënat hyrëse përbëhen nga veçori (features), të cilat janë atributet që përdoren për të përshkruar një rast të caktuar. Për shembull, në një model që parashikon çmimin e një shtëpie, features mund të jenë sipërfaqja, numri i dhomave, lokacioni dhe vjetërsia e ndërtesës. Ndërsa rezultati që modeli parashikon quhet target variable ose label.

Në përgjithësi, ekzistojnë tre lloje kryesore të Machine Learning:

- **Supervised Learning (Mësimi i mbikëqyrur)**

Në këtë lloj, modeli trajnohet mbi të dhëna që përmbajnë si input ashtu edhe output të njohur. Qëllimi është që modeli të mësojë lidhjen midis tyre në mënyrë që të mund të bëjë parashikime për të dhëna të reja. Shembuj tipikë janë klasifikimi dhe regresioni.

- **Unsupervised Learning (Mësimi i pambikëqyrur)**

Në këtë rast, të dhënat nuk kanë etiketa (labels), dhe modeli përpiqet të gjejë struktura ose grupe të fshehura brenda të dhënave. Një shembull i zakonshëm është clustering, ku të dhënat ndahen në grupe bazuar në ngjashmëri.

- **Reinforcement Learning (Mësimi përmes përforsimit)**

Ky lloj bazohet në një agjent që ndërvepron me një mjedis dhe mëson përmes shpërblimeve ose ndëshkimeve. Qëllimi është që agjenti të mësojë një strategji optimale veprimi për të maksimizuar shpërblimin total në kohë.

Një aspekt tjetër shumë i rëndësishëm në Machine Learning është procesi i ndarjes së të dhënave në grupe të ndryshme, zakonisht në të dhëna për trajnim (training set) dhe të dhëna për testim (testing set). Kjo ndarje siguron që modeli të vlerësohet mbi të dhëna të reja që nuk i ka parë më parë, duke dhënë një vlerësim më realist të performancës së tij.

Në përgjithësi, Machine Learning ka sjellë një revolucion në mënyrën e përpunimit të të dhënave dhe marrjes së vendimeve automatike. Megjithatë, kompleksiteti i modeleve moderne ka sjellë sfida të reja, veçanërisht në aspektin e interpretueshmërisë, e cila do të trajtohet në pjesët në vijim të këtij punimi.

2.2 Modelet “Black Box” dhe sfidat e interpretueshmërisë

Në fushën e Machine Learning, shumë nga algoritmet më të avancuara dhe më të përdorura sot karakterizohen si modele “Black Box”. Ky term përdoret për të përshkruar modele të cilat mund të ofrojnë rezultate shumë të sakta, por mënyra se si ato arrijnë deri te këto rezultate nuk është lehtësisht e kuptueshme për përdoruesin apo edhe për vetë zhvilluesin në disa raste. Me fjalë të tjera, input-i dhe output-i janë të dukshëm, por procesi i brendshëm i vendimmarrjes mbetet i fshehur.[4]

Modelet si rrjetet nervore të thella (Deep Neural Networks), Random Forest dhe Gradient Boosting Machines janë shembuj tipikë të modeleve “Black Box”. Këto modele kanë aftësi të larta për të kapur marrëdhënie komplekse jo-lineare në të dhëna, gjë që i bën ato shumë të fuqishme në aplikime praktike. Megjithatë, kjo kompleksitet i brendshëm e bën të vështirë interpretimin e faktorëve që ndikojnë në një parashikim të caktuar.




Figura 2.2: Modelet Black Box

Sfida kryesore e interpretueshmërisë qëndron në mungesën e transparencës së procesit të vendimmarrjes. Në shumë raste, përdoruesit nuk mund të kuptojnë pse një model ka dhënë një rezultat të caktuar, cilat veçori (features) kanë ndikuar më shumë në atë vendim, dhe në çfarë mënyre janë kombinuar këto faktorë. Kjo mungesë e qartësisë krijon vështirësi në besimin dhe përdorimin e këtyre sistemeve në situata kritike.

Një problem i rëndësishëm që lidhet me modelet “Black Box” është edhe vështirësia në identifikimin e gabimeve dhe paragjykimeve (bias). Nëse një model merr vendime të gabuara ose të padrejta, është shpesh e vështirë të kuptohet burimi i problemit, pasi nuk është e qartë se cilat pjesë të të dhënave apo cilat veçori kanë ndikuar në rezultatin përfundimtar. Kjo e bën procesin e debugimit dhe përmirësimit të modelit më kompleks.

Gjithashtu, në shumë aplikacione reale, veçanërisht në fusha si shëndetësia, financat dhe siguria, mungesa e interpretueshmërisë mund të sjellë probleme serioze.[4] Për shembull, një model që refuzon një kërkesë kredie duhet të jetë në gjendje të shpjegojë arsyet e këtij vendimi, në mënyrë që institucioni financiar dhe klienti të kuptojnë logjikën pas tij. Në mungesë të këtij shpjegimi, vendimet e modelit mund të duken arbitrare dhe të pabesueshme.

Një tjetër sfidë lidhet me aspektin etik dhe ligjor të përdorimit të inteligjencës artificiale. Me rritjen e përdorimit të sistemeve automatike në vendimmarrje, është rritur edhe kërkesa për transparencë dhe llogaridhënie. Në disa raste, rregulloret kërkojnë që vendimet e marra nga sistemet inteligjente të

jenë të shpjgueshme dhe të justifikueshme, gjë që nuk është gjithmonë e mundur me modelet “Black Box”.

Për këto arsye, interpretueshmëria është bërë një nga çështjet më të rëndësishme në Machine Learning modern. Nevoja për të kuptuar dhe shpjeguar vendimet e modeleve ka çuar në zhvillimin e fushës së Explainable Artificial Intelligence (XAI), e cila synon të adresojë këto sfida duke ofruar metoda dhe teknika që bëjnë modelet më transparente dhe më të kuptueshme për përdoruesit.

Në këtë kuadër, metoda si SHAP dhe LIME luajnë një rol të rëndësishëm, pasi ato ofrojnë mënyra të ndryshme për të analizuar dhe interpretuar vendimet e modeleve komplekse, duke ndihmuar në rritjen e besueshmërisë dhe përdorshmërisë së tyre në aplikime reale.

2.3 Explainable Artificial Intelligence (XAI)

Explainable Artificial Intelligence (XAI) është një fushë e inteligjencës artificiale që fokusohet në zhvillimin e metodave dhe teknikave që bëjnë të mundur interpretimin dhe kuptimin e vendimeve të modeleve të Machine Learning. Qëllimi kryesor i XAI është të rrisë transparencën e sistemeve inteligjente, duke i bërë ato më të kuptueshme për përdoruesit, zhvilluesit dhe palët e interesuara.

Në modelet tradicionale të Machine Learning, sidomos ato komplekse, rezultati përfundimtar shpesh nuk shoqërohet me një shpjegim të qartë. Kjo krijon një “hendek të interpretueshmërisë” midis performancës së modelit dhe kuptueshmërisë së tij. XAI synon të mbushë këtë hendek duke ofruar mekanizma që shpjegojnë pse një model ka marrë një vendim të caktuar dhe cilat faktorë kanë ndikuar më shumë në atë vendim.

Një nga aspektet kryesore të XAI është dallimi midis shpjgueshmërisë globale dhe asaj lokale.[3] Shpjgueshmëria globale fokusohet në kuptimin e sjelljes së përgjithshme të modelit, duke analizuar se si ai reagon në përgjithësi ndaj të dhënave hyrëse. Nga ana tjetër, shpjgueshmëria lokale fokusohet në shpjegimin e një parashikimi të vetëm ose të një rasti specifik. Metoda si SHAP dhe LIME janë të njohura për ofrimin e shpjgimeve lokale për vendimet e modeleve.

Rëndësia e XAI është rritur ndjeshëm në vitet e fundit për shkak të përdorimit të gjerë të inteligjencës artificiale në fusha kritike. Në sektorin e shëndetësisë, XAI ndihmon mjekët të kuptojnë arsyet pas diagnozave të gjeneruara nga modelet. Në financa, ndihmon në shpjegimin e vendimeve për kredi ose risk financiar. Në sigurinë kibernetike, kontribuon në identifikimin e kërcënimeve dhe analizimin e sjelljeve anormale.

Një tjetër arsye për rëndësinë e XAI është rritja e kërkesave për transparencë dhe përgjegjshmëri në sistemet e inteligjencës artificiale. Përdoruesit dhe institucionet kërkojnë që vendimet e automatizuara të jenë të justifikueshme dhe të auditueshme. Kjo është veçanërisht e rëndësishme në kontekste ligjore dhe etike, ku vendimet e sistemit mund të kenë pasoja të rëndësishme për individët.[3]

Përveç kësaj, XAI ndihmon edhe në përmirësimin e vetë modeleve të Machine Learning. Duke analizuar shpjegimet e gjeneruara, zhvilluesit mund të identifikojnë gabime, paragjykime dhe pjesë të dobëta të modelit, duke e përmirësuar atë në mënyrë të vazhdueshme. Kjo e bën XAI jo vetëm një mjet për interpretim, por edhe një instrument për optimizim dhe zhvillim më të mirë të sistemeve inteligjente.

Në këtë kontekst, metodat SHAP dhe LIME kanë fituar rëndësi të veçantë, pasi ofrojnë mënyra të ndryshme për të interpretuar modelet komplekse të Machine Learning. Ato përdoren gjerësisht në kërkime dhe aplikime praktike për të rritur transparencën dhe besueshmërinë e sistemeve inteligjente.

2.4 Siguria dhe besueshmëria në sistemet inteligjente

Siguria dhe besueshmëria janë dy nga aspektet më të rëndësishme në zhvillimin dhe përdorimin e sistemeve të bazuara në Inteligjencë Artificiale dhe Machine Learning. Me rritjen e përdorimit të këtyre sistemeve në fusha kritike, si shëndetësia, financat, transporti dhe siguria kibernetike, është bërë e domosdoshme që rezultatet e tyre të jenë jo vetëm të sakta, por edhe të besueshme dhe të justifikueshme.

Besueshmëria në sistemet inteligjente lidhet me aftësinë e modelit për të prodhuar rezultate të qëndrueshme dhe të sakta në kushte të ndryshme të të dhënave. Një model konsiderohet i besueshëm nëse ai ruan performancën e tij edhe kur përballet me të dhëna të reja, të ndryshme nga ato me të cilat është trajnuar. Megjithatë, në praktikë, modelet e Machine Learning mund të jenë të ndjeshme ndaj ndryshimeve në të dhëna, gjë që mund të ndikojë në saktësinë dhe stabilitetin e tyre.

Nga ana tjetër, siguria në sistemet inteligjente përfshin mbrojtjen e modeleve nga sulmet, manipulimet dhe keqpërdorimet e mundshme. Modelet e Machine Learning mund të jenë të ekspozuara ndaj sulmeve si “adversarial attacks”, ku të dhënat hyrëse manipulohen në mënyrë të tillë që modeli të prodhojë rezultate të gabuara. Kjo paraqet një rrezik serioz, veçanërisht në aplikime ku vendimet automatike kanë pasoja të rëndësishme.[3]

Një tjetër aspekt i rëndësishëm i sigurisë lidhet me cilësinë dhe integritetin e të dhënave. Nëse të dhënat e përdorura për trajnim përmbajnë gabime, mungesa ose paragjykime, atëherë edhe modeli do të mësojë këto defekte dhe do t’i pasqyrojë ato në vendimet e tij. Për këtë arsye, procesi i përgatitjes

së të dhënave konsiderohet një nga hapat më kritikë në ndërtimin e sistemeve të besueshme të Machine Learning.

Explainable Artificial Intelligence (XAI) luan një rol të rëndësishëm në rritjen e sigurisë dhe besueshmërisë së këtyre sistemeve.[3] Duke ofruar shpjegime për vendimet e modelit, XAI ndihmon në identifikimin e sjelljeve të pazakonta, gabimeve dhe paragjykimeve të mundshme. Kjo i lejon zhvilluesit të kuptojnë më mirë funksionimin e modelit dhe të ndërmarrin masa për përmirësimin e tij.

Për më tepër, interpretueshmëria kontribuon në rritjen e transparencës dhe llogaridhënies së sistemeve inteligjente. Kur vendimet e një modeli mund të shpjegohen në mënyrë të qartë, përdoruesit dhe institucionet kanë më shumë besim në përdorimin e tij. Kjo është veçanërisht e rëndësishme në kontekste ku vendimet automatike ndikojnë drejtpërdrejt në jetën e njerëzve ose në funksionimin e organizatave.

Në këtë kuadër, metodat si SHAP dhe LIME ndihmojnë në analizimin e faktorëve që ndikojnë në vendimet e modeleve, duke rritur transparencën dhe duke kontribuar në ndërtimin e sistemeve më të sigurta dhe më të besueshme. Përmes këtyre metodave, është e mundur të kuptohet më mirë sjellja e modeleve komplekse dhe të identifikohen rreziqet potenciale në përdorimin e tyre praktik.

2.5 Analiza e punimeve ekzistuese mbi SHAP dhe LIME

Në literaturën shkencore të viteve të fundit, metodat e Explainable Artificial Intelligence (XAI), veçanërisht SHAP dhe LIME, kanë marrë një vëmendje të konsiderueshme për shkak të rëndësisë së tyre në interpretimin e modeleve komplekse të Machine Learning. Këto metoda janë përdorur gjerësisht në studime akademike dhe aplikime praktike për të analizuar dhe shpjeguar vendimet e modeleve “Black Box”.

Metoda LIME (Local Interpretable Model-Agnostic Explanations) është një nga qasjet më të hershme dhe më të njohura për shpjegimin lokal të parashikimeve të modeleve. Ajo është përdorur në shumë punime kërkimore për të ofruar shpjegime të thjeshta dhe të kuptueshme për vendime individuale të modeleve, duke përafëruar sjelljen e modelit kompleks me një model më të thjeshtë dhe të interpretueshëm në nivel lokal. Për shkak të fleksibilitetit të saj, LIME është aplikuar në fusha të ndryshme si klasifikimi i tekstit, analiza e imazheve dhe sistemet e rekomandimit.

Nga ana tjetër, SHAP (SHapley Additive Explanations) është një metodë më e re që bazohet në teorinë e lojërave dhe konceptin e vlerave të Shapley[1]. Ajo ofron një mënyrë më të strukturuar dhe

teorikisht më të fortë për interpretimin e kontributit të secilës veçori në një parashikim të caktuar. SHAP është përdorur në një numër të madh studimesh për shkak të konsistencës së tij matematikore dhe aftësisë për të ofruar shpjegime si në nivel lokal ashtu edhe global.

Krahasimet midis SHAP dhe LIME janë trajtuar në disa punime shkencore, ku është vlerësuar performanca e tyre në aspektin e stabilitetit, saktësisë së shpjegimeve dhe kompleksitetit llogaritës. Në përgjithësi, SHAP konsiderohet më i qëndrueshëm dhe më i saktë në shpërndarjen e kontributeve të veçorive, ndërsa LIME vlerësohet për thjeshtësinë dhe shpejtësinë e implementimit [3,7]. Megjithatë, të dy metodat kanë kufizime të caktuara që varen nga lloji i të dhënave dhe modeli i përdorur.

Në literaturë është vënë re gjithashtu se përdorimi i SHAP dhe LIME kontribuon ndjeshëm në rritjen e transparencës së modeleve të Machine Learning, duke i bërë ato më të kuptueshme për përdoruesit jo-teknikë dhe ekspertët e fushës. Kjo ka çuar në adoptimin e tyre në shumë aplikacione reale, ku interpretueshmëria është një kërkesë e domosdoshme.

Përfundimisht, analiza e punimeve ekzistuese tregon se SHAP dhe LIME janë ndër metodat më të rëndësishme në fushën e Explainable AI, dhe përdorimi i tyre vazhdon të rritet në mënyrë të vazhdueshme në kërkime akademike dhe aplikime industriale. Kjo e bën studimin dhe krahasimin e tyre një temë me rëndësi të veçantë për zhvillimin e mëtejshëm të sistemeve inteligjente transparente dhe të besueshme.

3. Metodat e Shpjegueshmërisë në Machine Learning

Në literaturën shkencore të fushës së Explainable Artificial Intelligence (XAI), ekzistojnë shumë qasje dhe metoda për interpretimin e modeleve të Machine Learning. Megjithatë, dy nga metodat që kanë tërhequr vëmendjen më të madhe të komunitetit shkencor dhe janë adoptuar gjerësisht në aplikime praktike janë SHAP dhe LIME. Secila prej tyre ofron një këndvështrim të ndryshëm mbi mënyrën se si duhet interpretuar dhe shpjeguar vendimet e modeleve komplekse.

Zgjedhja e këtyre dy metodave si objekt studimi nuk është rastësore. SHAP dhe LIME përfaqësojnë dy filozofi të ndryshme të shpjegueshmërisë njëra e bazuar në teori të lojërave me garanci matematikore të forta, dhe tjetra e bazuar në përafrimin lokal intuitiv. Krahësimi i tyre teorik, i paraqitur në këtë kapitull, ofron themelin konceptual të domosdoshëm para se këto metoda të zbatohen praktikisht në kapitujt vijues të punimit.

3.1 Metoda SHAP

3.1.1 Bazat teorike të SHAP

SHAP (SHapley Additive exPlanations) është një metodë e Explainable AI e propozuar nga Lundberg dhe Lee në vitin 2017 [1], e cila bazohet në teorinë e lojërave kooperative të matematikanit Lloyd Shapley. Ideja themelore e kësaj metode qëndron në llogaritjen e kontributit marginal të çdo veçorie (feature) në parashikimin e modelit, duke marrë parasysh të gjitha kombinimet e mundshme të veçorive.

Vlerat e Shapley, nga të cilat SHAP merr emrin dhe bazën matematikore, janë një koncept i teorisë së lojërave që mundëson shpërndarjen e drejtë të kontributit mes lojtarëve (veçorive) në një lojë kooperative [8]. Në kontekstin e Machine Learning, 'lojtarët' janë veçoritë e inputit dhe 'fitimi' është ndikimi i tyre i kombinuar në parashikimin përfundimtar të modelit.

Konceptualisht, SHAP iu përgjigjet pyetjes: "Nëse modeli mesatarisht parashikon vlerën ϕ_0 , sa ka kontribuar secila veçori e veçantë që parashikimi i këtij rasti specifik të jetë $f(x)$?" Kjo e bën SHAP jashtëzakonisht të dobishëm, sepse jo vetëm tregon cila veçori është e rëndësishme, por edhe sa dhe në çfarë drejtimi ka ndikuar ajo.




Figura 3.1.1: Shpërndarja e kontributeve të veçorive sipas principit të Shapley Values. Çdo veçori merr kontributin e saj marginal mesatar mbi të gjitha kombinimet e mundshme.

Formulimi matematikor i vlerës SHAP për veçorinë i është:

$$\phi_i = \sum_{S \subseteq F, i \in S} \frac{(|S|-1)! (|F|-|S|)!}{|F|!} [f(S \cup \{i\}) - f(S)]$$

Ku S është bashkësia e veçorive pa veçorinë i , F është bashkësia e të gjitha veçorive, dhe $f(S)$ është parashikimi i modelit duke përdorur vetëm veçoritë e bashkësisë S . Faktori faktorial siguron që secila kombinim të ketë peshë të barabartë, pavarësisht nga renditja e veçorive.

Pse është i rëndësishëm formulimi matematikor? Vlerat e Shapley janë të vetmet vlera shpjegimi që plotësojnë njëkohësisht katër karakteristika themelore: Efikasitetin (shuma e kontributeve = diferenca e parashikimit), Simetrinë (veçori me kontribute të barabarta marrin vlera të barabarta), Dummy-në (veçori pa ndikim marrin vlerë zero) dhe Aditivitetin (kontributet e modeleve të kombinuara janë shuma e kontributeve individuale). Kjo i jep SHAP një bazë teorike unike ndër metodat e shpjegueshmërisë.

3.1.2 Shapley Values dhe interpretimi i rezultateve

Çdo vlerë SHAP φ_i tregon ndikimin e veçorisë i në parashikimin e modelit për një rast specifik. Interpretimi është i drejtpërdrejtë: vlerat pozitive tregojnë kontribut drejt klasës pozitive, ndërsa vlerat negative tregojnë kontribut drejt klasës negative. Shuma e të gjitha vlerave SHAP plus vlera bazë φ_0 jep parashikimin përfundimtar:

$$f(\mathbf{x}) = \varphi_0 + \varphi_1 + \varphi_2 + \dots + \varphi_n$$

Ku φ_0 është vlera bazë (expected value i modelit mesatarja e të gjitha parashikimeve) dhe $\varphi_1 \dots \varphi_n$ janë kontributet e çdo veçorie. Kjo pronësi additive e bën SHAP shumë transparente në çdo moment mund të verifikohet matematikisht se parashikimi është shuma e drejtpërdrejtë e vlerës bazë dhe kontributeve individuale.

Në literaturën dhe implementimet praktike të SHAP, dallohen disa lloje kryesore vizualizimi, secili duke iu përgjigjur një nevojë të ndryshme interpretimi:

- **Summary Plot (Beeswarm Plot):** tregon shpërndarjen e vlerave SHAP për të gjitha veçoritë dhe të gjitha rastet e një bashkësie të dhënash njëkohësisht. Çdo pikë përfaqëson një rast individual, ngjyra e pikës zakonisht tregon vlerën aktuale të veçorisë (e kuqe = e lartë, blu = e ulët), ndërsa pozicioni horizontal tregon drejtimin dhe magnitudën e ndikimit në parashikim.
- **Waterfall Plot:** shpjegon një parashikim të vetëm, individual, duke treguar hap pas hapi si secila veçori e 'shtyn' parashikimin lart ose poshtë, duke filluar nga vlera bazë φ_0 dhe duke arritur te vlera përfundimtare $f(\mathbf{x})$. Është vizualizimi më i përshtatshëm për shpjegime lokale të kuptueshme.
- **Bar Plot:** tregon rëndësinë mesatare absolute të çdo veçorie mbi gjithë bashkësinë e të dhënave, duke ofruar një renditje të qartë të veçorive sipas ndikimit të tyre global pa specifikuar drejtimin (pozitiv/negativ) e ndikimit.

Për modele të bazuara në pemë vendimore (decision trees), si Random Forest ose Gradient Boosting, ekziston një variant i optimizuar i quajtur **TreeExplainer**, i cili shfrytëzon strukturën e brendshme të pemëve për të llogaritur vlerat SHAP me kompleksitet llogaritës polinomial, në vend të kompleksitetit eksponencial të metodës së përgjithshme KernelSHAP. Kjo optimizim e bën TreeExplainer-in dukshëm më të shpejtë dhe praktikisht të aplikueshëm mbi modele me shumë veçori dhe shumë rrekorde, pa sakrifikuar saktësinë e vlerave Shapley të llogaritura[9].

3.1.3 Avantazhet dhe kufizimet e SHAP

Siç me çdo metodë shpjegueshmërie, edhe SHAP ka avantazhe të qarta dhe kufizime që duhen marrë parasysh gjatë aplikimit praktik.

Avantazhet e SHAP	Kufizimet e SHAP
Bazë e fortë matematikore (teoria e Shapley garanton drejtësi, eficiencë dhe konsistencë)	Kompleksitet llogaritës i lartë $O(2^n)$ për KernelSHAP në rastin e përgjithshëm
Ofron shpjegime si globale (Summary/Bar Plot) ashtu edhe lokale (Waterfall Plot)	TreeSHAP funksionon vetëm me modele të bazuara në pemë vendimore
Rezultate deterministike të njëjtat të dhëna japin gjithmonë të njëjtat rezultate SHAP	Vlerat numerike mund të jenë të vështira për t'u interpretuar nga përdoruesit jo-teknikë
Konsistencë nëse roli i një veçorie rritet në model, vlera e saj SHAP gjithmonë rritet	Presupozimi i pavarësisë mes veçorive mund të çojë në shpjegime jo të sakta kur veçoritë janë të korreluara
Shuma e vlerave SHAP gjithmonë i rikonstituon parashikimin e modelit (aditivitet)	Për modele shumë të mëdha, edhe TreeSHAP mund të jetë i ngadaltë

3.2 Metoda LIME

3.2.1 Bazat teorike të LIME

LIME (Local Interpretable Model-Agnostic Explanations) është propozuar nga Ribeiro, Singh dhe Guestrin në vitin 2016 [2] dhe paraqet një qasje krejtësisht të ndryshme nga SHAP. Ideja themelore e LIME qëndron në faktin se edhe nëse modeli global është shumë kompleks dhe jo-linear, sjellja e tij *rreth një pike specifike* të të dhënave mund të përafrohej me një model të thjeshtë linear. Kjo e bën LIME plotësisht **model-agnostic**, funksionon me çdo algoritëm ML pa pasur nevojë të aksesojë brendësinë e modelit.

Konceptualisht, LIME iu përgjigjet pyetjes: "Nëse zëvendësojmë modelin kompleks me një model shumë të thjeshtë vetëm *rreth këtij rasti specifik*, çfarë do na tregonte ai model i thjeshtë mbi

ndikimin e veçorive?" Kjo qasje e bën LIME shumë intuitiv shpjegimet dalin si kushte logjike, si për shembull 'failures ≤ 0.50 ' ose 'absences > 8 ', të cilat janë lehtë të kuptueshme edhe nga përdoruesit jo-teknikë.

Matematikisht, LIME zgjidh problemin e optimizimit :

$$\xi(\mathbf{x}) = \underset{\mathbf{g}}{\operatorname{argmin}} \quad L(\mathbf{f}, \mathbf{g}, \pi_{\mathbf{x}}) + \Omega(\mathbf{g})$$

Ku $\mathbf{f}$ është modeli original kompleks, $\mathbf{g}$ është modeli i thjeshtë shpjegues (zakonisht regresion linear), $\pi_{\mathbf{x}}$ është funksioni i peshimit që u jep rëndësi më të madhe rasteve të afërta me instancën $\mathbf{x}$, dhe $\Omega(\mathbf{g})$ është kompleksiteti i modelit shpjegues (penalitet për modele shumë komplekse).




Figura 3.2.1: LIME krijon shembuj fiktivë rreth instancës (x^*) dhe parashikon për ta me modelin kompleks. Pastaj trajnon model linear (vijë e ndërprerë) mbi ato parashikime - koeficientët janë shpjegimet.

3.2.2 Interpretimi lokal i modeleve

Procesi i funksionimit të LIME ndjek katër hapa kryesorë, të cilët mund të përmbliidhen si vijon:

- **Perturbimi:** gjenerohen mostra 'fiktive' rreth instancës që shpjegohet, zakonisht disa qindra deri në disa mijëra, duke ndryshuar vlerat e veçorive bazuar në shpërndarjen e të dhënave të trajnimit. Mostrat fiktive janë 'fqinjë' të instancës origjinale, por jo identikë me të.
- **Parashikimi:** modeli original kompleks parashikon për të gjitha mostrat fiktive. Kjo jep një pasqyrë të sjelljes lokale të modelit rreth pikës së interesit, pa kërkuar akses në strukturën e brendshme të modelit.
- **Peshat:** çdo mostër fiktive merr peshë bazuar në afërsinë e saj me instancën origjinale mostrat më të afërta marrin peshë më të lartë. Funkzioni i peshimit zakonisht është eksponencial dhe bazuar në një metrikë distance, si distanca euklidiane.
- **Regresioni:** trajnohet një model linear i thjeshtë mbi parashikimet e peshuara. Koeficientët e këtij regresioni janë vetë vlerat shpjeguese të LIME ato tregojnë se sa dhe në çfarë drejtimi ndikon secila veçori në rastin specifik që shpjegohet.

Rezultati final i LIME është një listë veçorish të shoqëruara me peshat e tyre, shprehura zakonisht si kushte logjike (p.sh. 'failures $\leq 0.00 \rightarrow +0.22$ '), në vend të thjesht vlerave numerike të vazhdueshme siç vepron SHAP. Kjo formë e shpjegimit, e diskutuar më në detaje në vijim, është një nga karakteristikat dalluese kryesore të LIME krahasuar me metodat e bazuara në teorinë e lojërave.

Vërejtje e rëndësishme për formatin e shpjegimit: Fakti që LIME shpreh shpjegimet si kushte logjike, në vend të vlerave numerike direkte, e bën këtë metodë veçanërisht të përshtatshme për audiencë jo-teknike si mësues, prindër, ose administratorë në kontekste të ndryshme aplikimi, pasi kushtet logjike janë më afër mënyrës natyrore të të arsyetuarit njerëzor krahasuar me vlerat abstrakte numerike.

3.2.3 Avantazhet dhe kufizimet e LIME

Siç edhe me SHAP, LIME ka karakteristikat e veta unike që e bëjnë të preferueshëm në situata të caktuara, por edhe kufizime që duhen pasur parasysh.

Avantazhet e LIME	Kufizimet e LIME
Plotësisht model-agnostic - punon me çdo algoritëm ML pa aksesuar brendësinë	Rezultate me variancë - ekzekutime të ndryshme mund të japin rezultate paksa të ndryshme

Shpjegime intuitive me kushte logjike - lehtë të kuptueshme nga jo-teknikët	Vetëm shpjegime lokale - nuk ofron pamje globale të sjelljes së modelit
I shpejtë dhe eficient - kosto llogaritëse e ulët krahasuar me KernelSHAP	Stabiliteti varet nga numri i perturbimeve dhe funksioni i peshimit
Fleksibël - mund të zbatohet në tekst, imazhe, tabela dhe lloje të tjera të dhënash	Modeli linear lokal mund të mos e kapë saktësisht sjelljen e modelit kompleks
Lehtë i implementueshëm dhe i integruar - libraria lime disponohet nëpërmjet pip	Asnjë garanci formale matematikore si ato të Shapley Values

3.3 Krahasimi teorik ndërmjet SHAP dhe LIME

Edhe pse SHAP dhe LIME ndajnë të njëjtin qëllim shpjegimin e vendimeve të modeleve të Machine Learning ato ndryshojnë ndjeshëm në qasje, filozofi dhe karakteristika praktike [7]. Kuptimi i këtyre dallimeve teorike është thelbësor për zgjedhjen e metodës së duhur në situata specifike, dhe formon bazën konceptuale mbi të cilën do të ndërtohet krahasimi eksperimental i paraqitur më vonë në Kapitullin 6.

Tabela e mëposhtme përmbledh dallimet kryesore teorike mes dy metodave, bazuar në literaturën akademike përkatëse:

Kriteri	SHAP	LIME
Baza matematikore	Teoria e lojërave - Shapley Values	Regresion linear lokal
Propozuar nga	Lundberg & Lee, 2017	Ribeiro, Singh & Guestrin, 2016
Lloji i shpjegimit	Global + Lokal	Vetëm Lokal
Stabiliteti	I lartë - rezultate deterministike	Mesatar - variancë ndërmjet ekzekutimeve

Format i shpjegimit	Vlera numerike (ϕ_i)	Kushte logjike (feature $\leq$ vlera)
Model-agnostic	Jo plotësisht (TreeSHAP kërkon pemë)	Po - punon me çdo model
Shpjegime globale	Po - Summary Plot, Bar Plot	Jo - vetëm shpjegime lokale
Garancitë teorike	Eficiencë, Simetri, Dummy, Aditivitet	Asnjë garanci formale
Lehtësia e interpretimit	Mesatare - kërkon njohuri teknike	E lartë - intuitive për jo-teknikët
Aplikimi ideal	Analizë institucionale, auditim i modelit	Shpjegim individual drejtuar përdoruesit

Nga krahasimi teorik i paraqitur më sipër, dallohen disa implikime konceptuale të rëndësishme që do të testohen empirikisht në kapitujt vijues të punimit:

- **Pritshmëria e konvergjencës:** pavarësisht ndryshimeve metodologjike, teorikisht pritet që SHAP dhe LIME të identifikojnë veçori të ngjashme si ndikuese kryesore, pasi të dyja metodat synojnë të kapin të njëjtën realitet të sjelljes së modelit nënkuptues, thjesht nga këndvështrime matematikore të ndryshme.
- **Pritshmëria e divergjencës në magnitudë:** meqenëse SHAP mat ndikimin mesatar mbi të gjitha kombinimet e mundshme të veçorive ndërsa LIME mat ndikimin lokal rreth një pike specifike, pritet që vlerat numerike të dy metodave të ndryshojnë në magnitudë absolute, edhe kur drejtimi i ndikimit (pozitiv/negativ) përputhet.
- **Tensioni teorik transparencë-privatësi:** meqenëse SHAP ofron shpjegime globale që agregojnë informacion mbi të gjithë dataset-in e trajnimit, ndërsa LIME mbetet i kufizuar në kontekst lokal, pritet teorikisht që SHAP të ekspozojë potencialisht më shumë informacion sensitiv mbi vetë dataset-in krahasuar me LIME një hipotezë që do të testohet konkretisht në analizën e privatësisë të Kapitullit 6.

Konkluzion i krahasimit teorik: Nga analiza e literaturës rezulton se SHAP dhe LIME nuk duhen konsideruar metoda konkurruese, por komplementare. SHAP paraqitet si metodë superiore për analiza

globale dhe institucionale ku kërkohet riprodhueshmëri dhe bazë matematikore e fortë, ndërsa LIME rezulton më i përshtatshëm për shpjegime individuale intuitive drejtuar përdoruesve jo-teknikë. Këto pritshmëri teorike formojnë hipotezat kryesore që do të testohen praktikisht përmes platformës së zhvilluar dhe rezultateve eksperimentale të paraqitura në kapitujt vijues të punimit.

4. Metodologjia dhe Arkitektura e Sistemit

Ky kapitull përshkruan procesin metodologjik të ndjekur për realizimin e këtij punimi, duke filluar nga zgjedhja dhe përgatitja e dataset-it, vazhduar me trajnimin e modelit të Machine Learning, dhe deri te integrimi i metodave SHAP dhe LIME brenda një platforme interaktive web. Qëllimi është të dokumentohet jo vetëm çfarë u realizua, por edhe pse u morën vendimet e caktuara metodologjike.

4.1 Përshkrimi i dataset-it

Për realizimin e eksperimenteve të këtij punimi u përdor *Student Performance Dataset*, një dataset publik i disponueshëm në UCI Machine Learning Repository[6]. Ky dataset është mbledhur nga Cortez dhe Silva në kuadër të një studimi mbi parashikimin e performancës akademike të studentëve të shkollave të mesme në Portugali, dhe është përdorur gjerësisht në literaturën e Machine Learning edukativ për shkak të pasurisë së veçorive socio-demografike që përmban.

Dataset-i përmban të dhëna për 395 studentë të lëndës së Matematikës, me 33 veçori (attributes) që mbulojnë aspekte personale, familjare, akademike dhe sociale të jetës së studentit si moshja, gjinia, niveli arsimor i prindërve, koha e studimit, numri i dështimeve të mëparshme, mungesat, konsumi i alkoolit, dhe shumë faktorë të tjerë.

Variabla target origjinale e dataset-it është nota finale G3 (në shkallë 0-20). Për qëllimet e këtij punimi, problemi u riformulua nga regresion në klasifikim binar: studenti konsiderohet se 'kalon' nëse $G3 \geq 10$, dhe 'nuk kalon' nëse $G3 < 10$. Kjo riformulim e bën problemin më të përshtatshëm për demonstrimin e metodave SHAP dhe LIME, të cilat janë veçanërisht intuitive në kontekstin e klasifikimit.

4.2 Përpunimi dhe përgatitja e të dhënave

Përgatitja e të dhënave përfshiu disa hapa standardë të domosdoshëm para trajnimit të modelit. Së pari, u krijua variabla target binare 'pass' bazuar në notën G3, siç u përshkrua më lart. Më pas, kolonat me vlera kategorike (si gjinia, adresa, profesioni i prindërve, mbështetja shkollë) u shndërruan në vlera numerike duke përdorur Label Encoding, një teknikë standarde që mundëson përdorimin e tyre nga algoritmet e Machine Learning, të cilat operojnë vetëm me të dhëna numerike.

Dataset-i u ndau në bashkësi trajnimi (train set) dhe bashkësi testimi (test set) në raportin 80%-20%, duke përdorur teknikën stratified sampling për të ruajtur proporcionin origjinal të klasave

(kalon/nuk kalon) në të dyja bashkësitë. Kjo është praktikë standarde në Machine Learning për të siguruar që vlerësimi i modelit të jetë i drejtë dhe i pavarur nga të dhënat e përdorura për trajnim.

Përmbledhje e të dhënave pas përgatitjes:

Karakteristika	Vlera
Studentë gjithsej	395
Veçori (features) për trajnim	30
Studentë që kalojnë (klasa 1)	265 (67.1%)
Studentë që nuk kalojnë (klasa 0)	130 (32.9%)
Bashkësia e trajnimit	316 studentë (80%)
Bashkësia e testimit	79 studentë (20%)

4.3 Zgjedhja dhe trajnimi i modelit Machine Learning

Algoritmi i zgjedhur për trajnim është **Random Forest Classifier**[5], një metodë ensemble e propozuar nga Breiman që kombinon shumë pemë vendimore (decision trees) të trajnuara në mënyrë të pavarur dhe i kombinon parashikimet e tyre nëpërmjet votimit shumice. Zgjedhja e Random Forest u bë për disa arsye konkrete të lidhura ngushtë me qëllimin e këtij punimi.

- **Performancë e fortë:** Random Forest është njohur si një nga algoritmet më të qëndrueshme për dataset-e tabulare me veçori të përziera (numerike dhe kategorike), siç është rasti me Student Performance Dataset.
- **Rezistencë ndaj mbifitimit:** Krahasuar me një pemë e vetme vendimore, Random Forest reduktohet ndjeshëm rrezikun e mbifitimit nëpërmjet mesatarizimit të shumë pemëve të trajnuara mbi nën-bashkësi të rastësishme të të dhënave.
- **Kompatibiliteti me TreeSHAP:** Random Forest mundëson përdorimin e TreeExplainer-it të SHAP, i cili llogarit vlerat Shapley në mënyrë eficiente duke shfrytëzuar strukturën e brendshme të pemëve, krahasuar me kohën e llogaritjes shumë më të gjatë që do të kërkonte KernelSHAP për modele të tjera.

Modeli u konfigurua me 100 pemë vendimore (`n_estimators=100`) dhe u fiksua një vlerë e parametrut `random_state` për të siguruar riprodhueshmërinë e plotë të rezultateve nëpër ekzekutime të ndryshme një kërkesë thelbësore për çdo punim shkencor.

Metrikat e vlerësimit të modelit:

Metrika	Vlera
Accuracy	67.09%
Precision	70.77%
Recall	86.79%
F1 Score	77.97%

Accuracy relativisht modeste (67.09%) është rrjedhojë e drejtpërdrejtë e vendimit metodologjik për të hequr notat G1 dhe G2, siç u shpjegua në seksionin 4.1. Recall i lartë (86.79%) tregon se modeli identifikon me sukses shumicën e studentëve që realisht kalojnë, ndërsa Precision relativisht më i ulët (70.77%) tregon se modeli prodhon edhe një numër të rrejshmesh pozitive studentë të parashikuar të kalojnë që në realitet nuk kalojnë. F1 Score (77.97%), si mesatare harmonike e Precision dhe Recall, konfirmon një balancë të pranueshme mes të dyjave, të anuar lehtësisht drejt Recall-it.

4.4 Integrimi i SHAP dhe LIME në sistem

Ky seksion përshkruan se si metodat SHAP dhe LIME, të trajtuara teorikisht në Kapitullin 3, u integruan praktikisht mbi modelin Random Forest të trajnuar në këtë punim, dhe çfarë rezultatesh konkrete prodhuan kur u zbatuan mbi Student Performance Dataset. Ndërsa Kapitulli 3 shpjegoi parimet e përgjithshme të SHAP dhe LIME të vlefshme për çdo model dhe dataset, ky seksion dokumenton implementimin specifik dhe gjetjet e para empirike që dolën nga ai implementim.

4.4.1 Integrimi teknik i SHAP

Për integrimin e SHAP mbi modelin Random Forest u përdor specifikisht TreeExplainer , varianti i optimizuar i bibliotekës shap për modele të bazuara në pemë vendimore. Zgjedhja e TreeExplainer-it, në vend të KernelExplainer-it të përgjithshëm, u bë për arsye thjesht praktike: TreeExplainer shfrytëzon strukturën e brendshme të pemëve të Random Forest-it për të llogaritur vlerat Shapley në kohë praktikisht të menjëhershme, ndërsa KernelSHAP do të kërkonte kohë llogaritëse shumë më të gjatë për të arritur të njëjtin rezultat.

```
explainer_shap = shap.TreeExplainer(model)
shap_values = explainer_shap.shap_values(X_test)
# shap_values.shape => (79, 30, 2)
# 79 studentë, 30 features, 2 klasa
```

Kodi 4.1: Inicializimi i SHAP TreeExplainer mbi modelin Random Forest dhe llogaritja e vlerave SHAP për bashkësinë e testimit.

Rezultatet e para nga aplikimi i SHAP

Pas llogaritjes së vlerave SHAP për të gjithë bashkësinë e testimit (79 studentë), u identifikuan veçoritë me rëndësinë globale më të lartë, të matura si mesatarja e vlerës absolute |SHAP| mbi të gjithë studentët:

Rangu	Feature	SHAP Score (mesatar)	Interpretimi
#1	failures	0.0702	Faktori më ndikues global-dështimet e kaluara
#2	absences	0.0436	Mungesat ndikojnë ndjeshëm negativisht
#3	goout	0.0376	Dalja me shokë ndikon në performancë
#4	age	0.0212	Mosha ka ndikim mesatar
#5	schoolsup	0.0163	Mbështetja shkollore ndikon pozitivisht




Figura 4.4.1: Summary Plot mbi 79 studentët e bashkësisë së testimit, i gjeneruar nga TreeExplainer mbi modelin Random Forest të trajnuar në këtë punim.

Përveç analizës globale, SHAP u zbatua edhe në nivel lokal për studentë individualë, duke gjeneruar Waterfall Plot që shpjegon hap pas hapi vendimin e modelit për një rast specifik. Për studentin referent

(failures=0, absences=6, studytime=2, schoolsup=1, higher=1, goout=4), të cilit modeli i parashikoi PASS me probabilitet 79%, faktorët kryesorë identifikuar nga SHAP ishin:

Veçoria	Vlera SHAP	Drejtimi
absences	+0.047	Pro PASS
failures	+0.041	Pro PASS
goout	+0.034	Pro PASS
sex	-0.027	Kundër PASS




Figura 4.4.1: Waterfall Plot i gjeneruar nga platforma për studentin referent (PASS, 79%).

4.4.2 Integrimi teknik i LIME

Për LIME u përdor klasa **LimeTabularExplainer**, varianti i bibliotekës lime i përshtatur posaçërisht për të dhëna tabulare strukturore siç është rasti i Student Performance Dataset. Ndryshe nga SHAP explainer-i, i cili u llogarit njëherë dhe u ruajt për ripërdorim, LimeTabularExplainer-i u rikrijua për çdo kërkesë individuale, për shkak të kufizimeve të serializimit të diskutuara në seksionin 5.2.1.

```
explainer_lime = LimeTabularExplainer(  
    X_train, feature_names=feature_names,  
    class_names=['Nuk kalon', 'Kalon'],  
    mode='classification', random_state=42  
)  
exp = explainer_lime.explain_instance(  
    student_data, model.predict_proba,  
    num_features=10  
)
```

Kodi 4.2: Inicializimi i LIME explainer-it dhe gjenerimi i shpjegimit për një student specifik.

Rezultatet e para nga aplikimi i LIME

Për të njëjtin student referent të analizuar me SHAP, LIME gjeneroi shpjegimin e mëposhtëm, të shprehur si kushte logjike mbi vlerat e veçorive:

Kushti LIME	Pesha	Interpretimi
failures $\leq$ 0.00	+0.2237	Mungesa e dështimeve ndikon shumë pozitivisht
schoolsup $\leq$ 0.00	+0.0656	Pa mbështetje shtesë - sinjal pozitiv
3.00 < absences $\leq$ 8.00	+0.0567	Mungesa të moderuara - brenda normales
guardian $\leq$ 1.00	+0.0407	Kujdestaria ndikon pozitivisht
2.00 < goout $\leq$ 3.00	+0.0323	Dalje mesatare me shokë - balancë
Walc $\leq$ 1.00	-0.0258	Konsumi i alkoolit ndikon negativisht




Figura 4.4.2: Vizualizimi LIME i gjeneruar nga analizat për studentin referent, jeshile pro PASS, e kuqe kundër.

4.4.3 Krahasimi i para-vërejtjeve nga integrimi

Integrimi paralel i SHAP dhe LIME mbi të njëjtin student lejoi një krahasim të menjëhershëm, ende para analizës së thelluar statistikore që do të kryhet në Kapitullin 6. Dy vërejtje dalin qartë edhe në këtë fazë fillestare të integritimit:

- **Konvergjencia e drejtimit:** të dyja metodat identifikojnë 'failures' dhe 'absences' si faktorë pozitivë kryesorë për studentin referent, duke konfirmuar njëra-tjetrën pavarësisht qasjeve të ndryshme matematikore.
- **Divergjencia në magnitudë:** LIME i jep veçorisë 'failures' një peshë (+0.2237) ndjeshëm më të lartë se SHAP (+0.041) një diferencë që do të analizohet në thellësi në seksionin 6.3, por që u vu re tashmë në këtë fazë të integritimit fillestar.

4.5 Arkitektura e platformës interaktive web

Platforma e zhvilluar, e quajtur XAI Explorer, ndjek një arkitekturë klasike klient-server me ndarje të qartë mes përpunimit të të dhënave (backend) dhe ndërfaqes së përdoruesit (frontend). Arkitektura është strukturuar në katër shtresa kryesore:

- **Shtresa e të dhënave:** Dataset-i CSV dhe modeli i trajnuar i ruajtur si skedarë pickle (model, feature names, training data, SHAP explainer).
- **Shtresa e logjikës (backend):** Server Flask që ngarkon modelet në momentin e nisjes dhe ekspozon disa endpoint-e API për parashikim, shpjegim SHAP, shpjegim LIME, krahasim dhe analizë privatësie.
- **Shtresa e vizualizimit:** Gjenerimi i grafikëve me Matplotlib, të cilët konvertohen në format base64 dhe transmetohen direkt te browser-i pa nevojën e skedarëve të përkohshëm në disk.
- **Shtresa e ndërfaqes (frontend):** Faqe web e ndërtuar me HTML, CSS dhe JavaScript, e organizuar në shtatë seksione tematike që korrespondojnë me hapat logjikë të analizës.

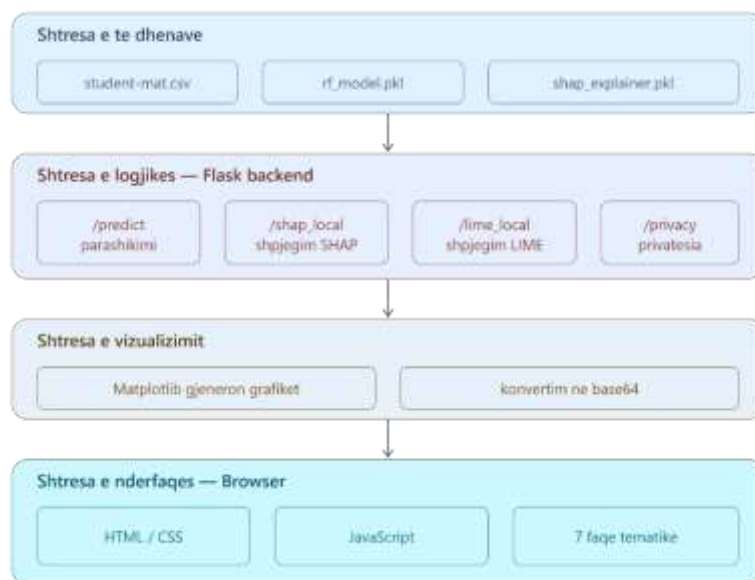


Figura 4.5: Rrjedha e të dhënave nga dataset-i te modeli, nëpërmjet backend-it Flask, deri te ndërfaqja e përdoruesit në browser.

4.6 Teknologjitë dhe mjetet e përdorura

Zgjedhja e teknologjive u udhëhoq nga kriteret e disponueshmërisë, mbështetjes aktive nga komuniteti shkencor, dhe përshtatshmërisë me kërkesat e punimit. Tabela e mëposhtme përmbledh stack-un teknologjik të përdorur në secilën shtresë të sistemit.

Komponenti	Teknologjia
Gjuha e programimit	Python 3.10

Machine Learning	scikit-learn
Shpjegueshmëria	shap, lime
Web Framework	Flask
Vizualizimi	Matplotlib
Frontend	HTML5, CSS3, JavaScript
Përpunimi i të dhënave	pandas, numpy

Flask u zgjodh si web framework për shkak të thjeshtësisë dhe integritetit të lehtë me libraritë e Machine Learning të shkruara në Python duke evituar nevojën për shtresa shtesë konvertimi mes gjuhëve të ndryshme programuese që do të nevojiteshin nëse do të përdorej, për shembull, një backend i shkruar në JavaScript ose Java.

5. Implementimi i platformës interaktive Web

Ndërsa Kapitulli 4 trajtoi vendimet metodologjike dhe arkitekturën konceptuale të sistemit, ky kapitull zbërthen në detaje procesin konkret të implementimit të platformës XAI Explorer nga dizajni i ndërfaqes deri te integrimi funksional i SHAP dhe LIME brenda një mjedisi web të plotë, funksional dhe të testueshëm. Ky kapitull përfaqëson thelbin praktik të punimit: pikën ku teoria e shpjegueshmërisë, e trajtuar në Kapitullin 3, shndërrohet në një sistem real që mund të përdoret, testohet dhe vlerësohet.

Platforma u zhvillua në mënyrë inkrementale dhe iterative. Fillimisht, eksperimentet u realizuan në mjedisin Jupyter Notebook, ku u testua trajnimi i modelit dhe gjenerimi i shpjegimeve SHAP dhe LIME në izolim. Pasi këto eksperimente konfirmuan funksionimin korrekt të metodave, logjika u migrua dhe u riorganizua brenda një aplikacioni Flask të plotë, të strukturuar në shtatë faqe tematike që korrespondojnë me hapat logjikë të procesit të shpjegueshmërisë nga parashikimi fillestar deri te analiza e implikacioneve të privatësisë.

5.1 Dizajni i sistemit

Procesi i dizajnit nisi me identifikimin e funksionaliteteve kryesore që platforma duhej të mbulonte për t'i përgjigjur plotësisht pyetjeve kërkimore të këtij punimi. U vendos që secili funksionalitet të jetë i izoluar në faqen e vet, në vend që të kombinohet brenda një ndërfaqeje të vetme të mbingarkuar një vendim dizajni i bazuar në parimin e ngarkesës kognitive të reduktuar, sipas të cilit informacioni i paraqitur njëkohësisht duhet kufizuar për të mos e tepruar përdoruesin me të dhëna.

5.1.1 Struktura modulare e shtatë faqeve

Faqja	Qëllimi kryesor	Të dhënat e shfaqura
Home	Orientim dhe statistika hyrëse	Numri i studentëve, features, accuracy, algoritmi
Prediction	Marrja e inputit dhe parashikimi	Formular 16 fushash, PASS/FAIL, probabiliteti
SHAP Analysis	Shpjegim global dhe lokal me SHAP	Summary Plot, Bar Plot, Waterfall Plot

LIME Analysis	Shpjegim lokal me LIME	Grafiku LIME, lista e peshave si kushte logjike
SHAP vs LIME	Krahasimi sasior i dy metodave	Tabelë krahasuese, grafik bar i dyfishtë, konkluzion
Privacy & Security	Vlerësimi i rrezikut të privatësisë	Feature Risk Score, Membership Inference Risk
Results	Përmbledhje akademike finale	Metrikat e modelit, gjetjet kryesore

Kjo strukturë lejon një rrjedhë logjike natyrore të përdorimit: përdoruesi fillimisht orientohet (Home), pastaj kryen një veprim konkret (Prediction), më pas eksploron shpjegimin nga dy këndvështrime të ndryshme (SHAP Analysis, LIME Analysis), i krahason ato drejtpërdrejt (SHAP vs LIME), vlerëson implikimet etike (Privacy & Security), dhe përmbledh gjetjet (Results). Kjo rrjedhë pasqyron vetë strukturën logjike të punimit të diplomës, duke krijuar një paralelizëm të qëllimshëm mes organizimit të platformës dhe organizimit të kërkimit shkencor që e mbështet.

5.1.2 Identiteti vizual dhe parimet e dizajnit

Identiteti vizual i platformës u bazua mbi një paletë me dy ngjyra dominante blu e errët (#003366) dhe ar (#FFB81C), të zgjedhura për të komunikuar njëkohësisht seriozitet akademik dhe energji vizuale. Blu e errët u përdor për elementet strukturore (header, sidebar, tabela krye), ndërsa ari u rezervua për elemente që kërkojnë vëmendje të menjëhershme të përdoruesit (butona kryesorë, indikatorë statusi, theksime në grafikë).

- **Konsistenca:** sidebar-i i navigimit mbetet vizualisht identik nëpër të gjitha faqet, duke i dhënë përdoruesit një referencë të qëndrueshme të vendndodhjes brenda aplikacionit.
- **Hierarkia vizuale:** titujt e faqeve, kartat (cards) dhe tabelat ndjekin një hierarki tipografike të qartë, duke ndihmuar përdoruesin të skanojë shpejt informacionin më të rëndësishëm.
- **Feedback i menjëhershëm:** çdo veprim i përdoruesit (parashikim, ngarkim grafiku) shoqërohet me indikator vizual ngarkimi, duke evituar konfuzionin nëse sistemi është 'i ngecur' apo thjesht duke përpunuar.




Figura 5.1.2: Dashboard-i hyrës me statistikën e dataset-it, modelin e përdorur dhe paraqitjen krahasuese fillestare SHAP/LIME.

5.2 Implementimi i backend-it

Backend-i i platformës u implementua duke përdorur Flask [11], një micro-framework Python i njohur për thjeshtësinë dhe fleksibilitetin e tij. Flask u zgjodh në vend të framework-eve më të mëdha si Django për shkak se platforma nuk kërkonte funksionalitete komplekse si menaxhim përdoruesish, autentikim, ose ORM për baza të dhënash vetëm një shtresë e lehtë API-sh që ndërmjetëson mes modelit ML dhe ndërfaqes së përdoruesit.

5.2.1 Ngarkimi i modelit në momentin e nisjes

Një vendim arkitektural kritik për performancën e platformës ishte ngarkimi i modelit, i emrave të veçorive, i bashkësisë së trajnimit dhe i SHAP explainer-it në memorie në momentin e nisjes së serverit Flask jo në çdo kërkesë individuale të përdoruesit. Kjo qasje, e njohur si 'model caching' në literaturën e MLOps, eliminon koston e përsëritur të deserializimit të skedarëve pickle, e cila do të ishte e papranueshme në termat e kohës së përgjigjes nëse do të kryhej për çdo kërkesë.

```
# Ngarkohet vetëm një herë, në startup të serverit
model = joblib.load('models/rf_model.pkl')
feature_names = joblib.load('models/feature_names.pkl')
X_train = joblib.load('models/X_train.pkl')
explainer_shap = shap.TreeExplainer(model)

explainer_lime = LimeTabularExplainer(
    X_train, feature_names=feature_names,
    class_names=['Nuk kalon', 'Kalon'],
    mode='classification', random_state=42
)
```

Kodi 5.1: Inicializimi i modeleve dhe explainer-ëve në momentin e nisjes së Flask.

5.2.2 Struktura e endpoint-eve API

Logjika e backend-it u organizua rreth shtatë endpoint-eve kryesore, secili duke iu përgjigjur një funksionaliteti specifik. Çdo endpoint ndjek të njëjtin model: pranon të dhëna (nëse është e nevojshme), kryen përpunimin me modelin ose explainer-ët, dhe kthen një përgjigje JSON të strukturuar që frontend-i e interpreton dhe e shfaq.

Endpoint	Metoda	Funksioni
/predict	POST	Merr 30 veçoritë e studentit, kthen klasën e parashikuar dhe probabilitetin
/shap_local	POST	Llogarit vlerat SHAP individuale dhe kthen Waterfall Plot si base64
/global_shap	GET	Gjeneron Summary Plot dhe Bar Plot mbi bashkësinë e testimit (79 studentë)
/lime_local	POST	Rikrijonë explainer-in LIME dhe gjeneron shpjegimin për studentin
/comparison	POST	Ekzekuton SHAP dhe LIME paralelisht, ndërton tabelën dhe grafikun krahasues

/privacy_features	GET	Llogarit Feature Risk Score dhe simulon Membership Inference Attack
/results	GET	Kthen metrikat finale (accuracy, precision, recall, F1) dhe gjetjet

5.2.3 Transmetimi i grafikëve: nga Matplotlib te browser

Një sfidë teknike specifike e këtij projekti ishte mënyra e transmetimit të grafikëve të gjeneruar nga Matplotlib drejt ndërfaqes së përdoruesit në browser. U konsideruan dy qasje: (a) ruajtja e grafikëve si skedarë statikë PNG në server dhe referimi i tyre përmes URL-ve, ose (b) konvertimi i grafikëve direkt në kohë reale në një format të transmetueshëm brenda vetë përgjigjes JSON. U zgjodh qasja e dytë, duke përdorur encoding base64.

```
def fig_to_base64(fig):
    buf = BytesIO()
    fig.savefig(buf, format='png', dpi=150,
                bbox_inches='tight')
    buf.seek(0)
    encoded = base64.b64encode(buf.read())
    plt.close(fig) # liron memorien
    return encoded.decode('utf-8')
```

Kodi 5.2: Konvertimi i një figure Matplotlib në string base64 për transmetim JSON.

Kjo qasje solli disa avantazhe konkrete: së pari, eliminoi nevojën për menaxhim skedarësh të përkohshëm dhe pastrimin periodik të tyre nga disku; së dyti, evitoi probleme të mundshme race condition në rast se dy përdorues të ndryshëm do të kërkonin grafikë njëkohësisht; së treti, e bëri platformën më të lehtë për t'u shpërndarë, pasi nuk kërkon konfigurim shtesë të një direktorie publike për skedarë statikë. Kostoja kryesore e kësaj qasjeje është madhësia paksa më e madhe e përgjigjeve JSON, e cila megjithatë u konsiderua e pranueshme për shkallën e këtij projekti.

5.3 Implementimi i ndërfaqes së përdoruesit

Ndërfaqja e përdoruesit u ndërtua me HTML, CSS dhe JavaScript pa përdorimin e ndonjë framework-u të jashtëm si React ose Vue. Ky vendim u mor qëllimisht: për shkallën dhe kompleksitetin

e këtij projekti, një framework i plotë do të shtonte kompleksitet të panevojshëm (bundling, state management, build tools) pa përfitime proporcionale, ndërsa JavaScript 'vanilla' mbetet plotësisht i mjaftueshëm për të menaxhuar navigimin mes shtatë faqeve dhe komunikimin asinkron me backend-in.

5.3.1 Komunikimi asinkron me backend-in

Çdo ndërveprim që kërkon të dhëna nga backend-i realizohet nëpërmjet API-së Fetch të JavaScript-it, e cila dërgon kërkesa HTTP asinkrone pa rifreskuar faqen. Kjo i jep platformës ndjenjën e një aplikacioni modern Single Page Application (SPA), edhe pse arkitektura e saj themelore mbetet më e thjeshtë se ajo e framework-eve SPA të plota.

```
async function runPredict() {
  const values = getFormValues();
  const res = await fetch('/predict', {
    method: 'POST',
    headers: {'Content-Type': 'application/json'},
    body: JSON.stringify({values})
  });
  const data = await res.json();
  showPrediction(data);
}
```

Kodi 5.3: Thirrja asinkrone fetch() për dërgimin e të dhënave të studentit te endpoint-i /predict.

5.3.2 Navigimi pa rifreskim faqeje

Shtatë faqet e platformës nuk janë URL të veçanta, por seksione të të njëjtit dokument HTML që fshihen dhe shfaqen selektivisht përmes manipulimit të DOM-it nga JavaScript. Kur përdoruesi klikon një element të sidebar-it, funksioni showPage() heq klasën CSS 'active' nga faqja aktuale dhe e shton te faqja e zgjedhur, duke kontrolluar shfaqjen e tyre përmes vetive CSS display.

Kjo qasje ka një avantazh të rëndësishëm praktik: meqenëse modeli dhe explainer-ët mbeten të ngarkuar në backend gjatë gjithë sesionit të përdoruesit (jo vetëm gjatë një kërkesë specifike), kalimi mes faqeve SHAP Analysis, LIME Analysis dhe SHAP vs LIME mund të ripërdorë të njëjtat vlera input të studentit pa pasur nevojë t'i ridërgojë ose t'i rivendosë.

5.3.3 Rrjedha e plotë e ndërveprimit të përdoruesit

Faqja Prediction strukturon të dhënat hyrëse të studentit në tre seksione tematike: informacion personal, arsimor dhe social, përdoruesi fut të dhënat e studentit duke plotësuar formularin siç ilustrohet në Figurën 5.3.




Figura 5.3.3: Formulari interaktiv i ndarë në tre seksione tematike - informacion personal, arsimor dhe social.

Plotësimi i formularit

1

Përdoruesi fut të dhënat e studentit në faqen Prediction - moshë, gjini, kohë studimi, dështime, mungesa, dhe faktorë socialë.

Dërgimi i kërkesës dhe ruajtja e gjendjes

2

Të dhënat dërgohen te /predict; vlerat ruahen gjithashtu në një variabël global JavaScript (lastInputValues) për ripërdorim të mëvonshëm.

Shfaqja e rezultatit fillestar

3

Platforma shfaq PASS ose FAIL me probabilitetin përkatës dhe një shirit progresi vizual proporcional me besueshmërinë e parashikimit.

Eksplorimi i shpjegimit SHAP

4

Përdoruesi kalon te faqja SHAP Analysis; vlerat e ruajtura më parë dërgohen automatikisht te /shap_local pa nevojën e rifutjes.

Eksplorimi i shpjegimit LIME

5

I njëjti proces përsëritet për /lime_local, duke siguruar që të dyja shpjegimet i referohen saktësisht të njëjtit student.

Krahasimi dhe vlerësimi etik

6

Përdoruesi mund të vizitojë faqet SHAP vs LIME dhe Privacy & Security për një analizë krahasuese dhe vlerësim të implikacioneve të privatësisë.

5.4 Gjenerimi i parashikimeve të modelit

Procesi i parashikimit fillon në momentin kur përdoruesi plotëson formularin dhe shtyp butonin Predict. Një aspekt teknik i rëndësishëm këtu lidhet me mospërputhjen mes numrit të fushave të dukshme në formular (16) dhe numrit total të veçorive që modeli pret si input (30). Kjo mospërputhje u trajtua duke kombinuar vlerat e futura nga përdoruesi me vlera të parazgjedhura (defaults) për veçoritë e mbetura, bazuar mbi vlerat mesatare ose më të shpeshta të tyre në dataset-in origjinal.

Vendim i diskutueshëm metodologjikisht: Fillimisht u konsiderua kufizimi i SHAP dhe LIME që të shpjegojnë vetëm 16 veçoritë e dukshme në formular. Megjithatë, ky vendim u rrëzua pas analizës, pasi do të krijonte shpjegime jo plotësisht të sakta nga pikëpamja matematikore SHAP dhe LIME funksionojnë mbi modelin e plotë me 30 veçori, dhe kufizimi artificial i tyre në vetëm

16 do të shtrembëronte vlerat reale Shapley dhe peshat LIME. U vendos që platforma të lërë SHAP dhe LIME të analizojnë të gjitha 30 veçoritë, edhe nëse disa prej tyre (si 'guardian' ose 'Walc') nuk shfaqen drejtpërdrejt në formular. Kjo zgjedhje metodologjike vetë përbën një gjetje interesante: shpjegimet zbulojnë ndikime që përdoruesi i formularit nuk i percepton drejtpërdrejt, duke demonstruar njërin nga vlerat thelbësore të XAI - zbulimin e faktorëve të 'fshehur' për përdoruesin fundor.

Backend-i thërret metodat `predict()` dhe `predict_proba()` të objektit `RandomForestClassifier` nga `scikit-learn`. Metoda e parë kthen klasën e parashikuar në formën e një numri të plotë (0 për 'nuk kalon', 1 për 'kalon'), ndërsa metoda e dytë kthen një çift probabilitetesh që shumohen në 1, probabiliteti i klasës 0 dhe probabiliteti i klasës 1. Platforma përdor probabilitetin e klasës 1 si vlerën e shfaqur, e konvertuar në përqindje për lexueshmëri më të mirë.

Rasti studimor referent i përdorur gjatë gjithë kapitullit: Për të siguruar konsistencë krahasuese mes seksioneve të mëposhtme, gjithë kapitulli i referohet të njëjtit student hipotetik: `failures=0`, `absences=6`, `studytime=2`, `schoolsup=1` (po), `higher=1` (dëshiron universitet), `goout=4` (i lartë). Platforma parashikoi PASS me probabilitet 79%.

5.5 Vizualizimi i rezultateve të SHAP

Vizualizimi i SHAP në platformë ndahet në dy nivele të dallueshme, secili i aksesueshëm përmes një tab-i të veçantë në faqen SHAP Analysis: Global Explanation dhe Local Explanation. Kjo ndarje nuk është thjesht estetike, por pasqyron një dallim konceptual themelor në vetë natyrën e metodës SHAP, e diskutuar tashmë teorikisht në Kapitullin 3.

5.5.1 Niveli global - sjellja e modelit në shkallë të gjerë

Niveli global, i ofruar nga endpoint-i `/global_shap`, gjeneron dy lloje grafikësh mbi të gjithë bashkësinë e testimit prej 79 studentësh: Summary Plot (i njohur edhe si Beeswarm Plot) dhe Bar Plot. Të dy grafikët llogariten njëherë dhe ruhen, pasi vlerat SHAP për bashkësinë e testimit nuk ndryshojnë mes kërkesave të ndryshme të përdoruesve një optimizim që evitoi rillogaritje të kushtueshme dhe të panevojshme.

Summary Plot është grafiku më informativ i platformës nga pikëpamja analitike, pasi kombinon në një figurë të vetme tri dimensione informacioni: rëndësinë e veçorisë (pozicioni vertikal), ndikimin në parashikim (pozicioni horizontal i çdo pike), dhe vlerën aktuale të veçorisë për atë student (ngjyra e pikës). Kjo dendësi informacioni e bën Summary Plot të vështirë për t'u interpretuar nga përdorues të papërgatitur, por jashtëzakonisht të vlefshëm për analizë akademike.



Figura 5.5.1: Summary Plot mbi 79 studentët e bashkësisë së testimit. Veçoria 'failures' dominon renditjen, me korrelacion të dukshëm mes vlerës së lartë (kuq) dhe ndikimit negativ.

5.5.2 Niveli lokal - Waterfall Plot për studentin specifik

Niveli lokal fokusohet specifikisht në studentin e parashikuar fundimisht nga përdoruesi. Pasi formulari dërgohet, vlerat hyrëse ridërgohen te endpoint-i /shap_local (duke ripërdorur lastInputValues të ruajtur në frontend), i cili llogarit vlerat Shapley individuale për këtë rast specifik dhe gjeneron një Waterfall Plot.

Waterfall Plot funksionon si një 'rrëfim vizual' i vendimit të modelit: fillon nga vlera bazë ϕ_0 (rreth 67%, mesatarja e parashikimeve të modelit mbi gjithë dataset-in), dhe çdo veçori 'shtyn' parashikimin lart ose poshtë, derisa arrihet vlera finale prej 79%. Për studentin referent të përdorur në këtë kapitull, faktorët kryesorë identifikuar nga platforma ishin:

Veçoria	Vlera SHAP	Drejtimi	Interpretimi
absences	+0.047	Pro PASS	Numri i ulët i mungesave (6) ndikon pozitivisht
failures	+0.041	Pro PASS	Zero dështime të kaluara - sinjal i fortë pozitiv
goout	+0.034	Pro PASS	Dalja mesatare me shokë - ndikim i moderuar
sex	-0.027	Kundër	Ndikim i vogël negativ, i pavarur nga zgjedhjet e studentit




Figura 5.5.2: Waterfall Plot për studentin referent (PASS, 79%). Shigjetat e gjelbra tregojnë faktorë pro PASS, ato të kuqe kundër.

Përveç grafikut grafik, platforma ekstraktonte programatikisht faktorët pozitivë dhe negativë kryesorë nga vlerat numerike SHAP, duke i renditur sipas magnitudës absolute dhe duke i ndarë në dy lista të dallueshme vizualisht (jeshile për pozitivë, e kuqe për negativë). Kjo veçori adresoi drejtpërdrejt një kufizim të njohur të SHAP vështirësinë e interpretimit nga audienca jo-teknike, e diskutuar në seksionin 3.1.3 duke e shndërruar një grafik shkencor në një listë të thjeshtë faktorësh pro/kundër.

5.6 Vizualizimi i rezultateve të LIME

Ndryshe nga SHAP, faqja LIME Analysis nuk përmban ndarje global/lokal, pasi siç u përshkrua teorikisht në seksionin 3.2, LIME është projektuar specifikisht si metodë e shpjegimit lokal dhe nuk ofron, nga vetë natyra e saj algoritmike, një mekanizëm për agregim global të besueshëm nëpër të gjithë dataset-in.

5.6.1 Rikrijimi i explainer-it dhe gjenerimi i shpjegimit

Endpoint-i /lime_local rikrijon LimeTabularExplainer-in për çdo kërkesë (siç u shpjegua në seksionin 5.2.1) dhe thërret metodën explain_instance(), duke specifikuar 10 si numrin e veçorive për t'u shfaqur. Ky numër u zgjodh si balancë mes plotësisë së informacionit dhe lexueshmërisë vizuale një grafik me 30 veçori do të ishte i ngarkuar dhe i vështirë për t'u interpretuar shpejt.

```
exp_lime = explainer_lime.explain_instance(  
    input_array[0],  
    model.predict_proba,  
    num_features=10  
)  
lime_list = exp_lime.as_list()  
# [('failures <= 0.00', 0.2237), ...]
```

Kodi 5.4: Gjenerimi i shpjegimit LIME për studentin referent.

5.6.2 Krahasimi i formatit të shpjegimit me SHAP

Rezultati i LIME për studentin referent konfirmoi gjetjet kryesore të SHAP, por me një diferencë të rëndësishme në format: ndërsa SHAP shpreh kontributin e 'failures' si një vlerë numerike të vazhdueshme (+0.041), LIME e shpreh të njëjtin faktor si kusht logjik diskret ('failures <= 0.00', peshë +0.2237). Kjo diferencë formati nuk është thjesht estetike ajo pasqyron dallimin themelor mes një metode të bazuar në kontribut marginal të vazhdueshëm (SHAP) dhe një metode të bazuar në një model linear lokal të përafëruar mbi mostra binarizuara (LIME).

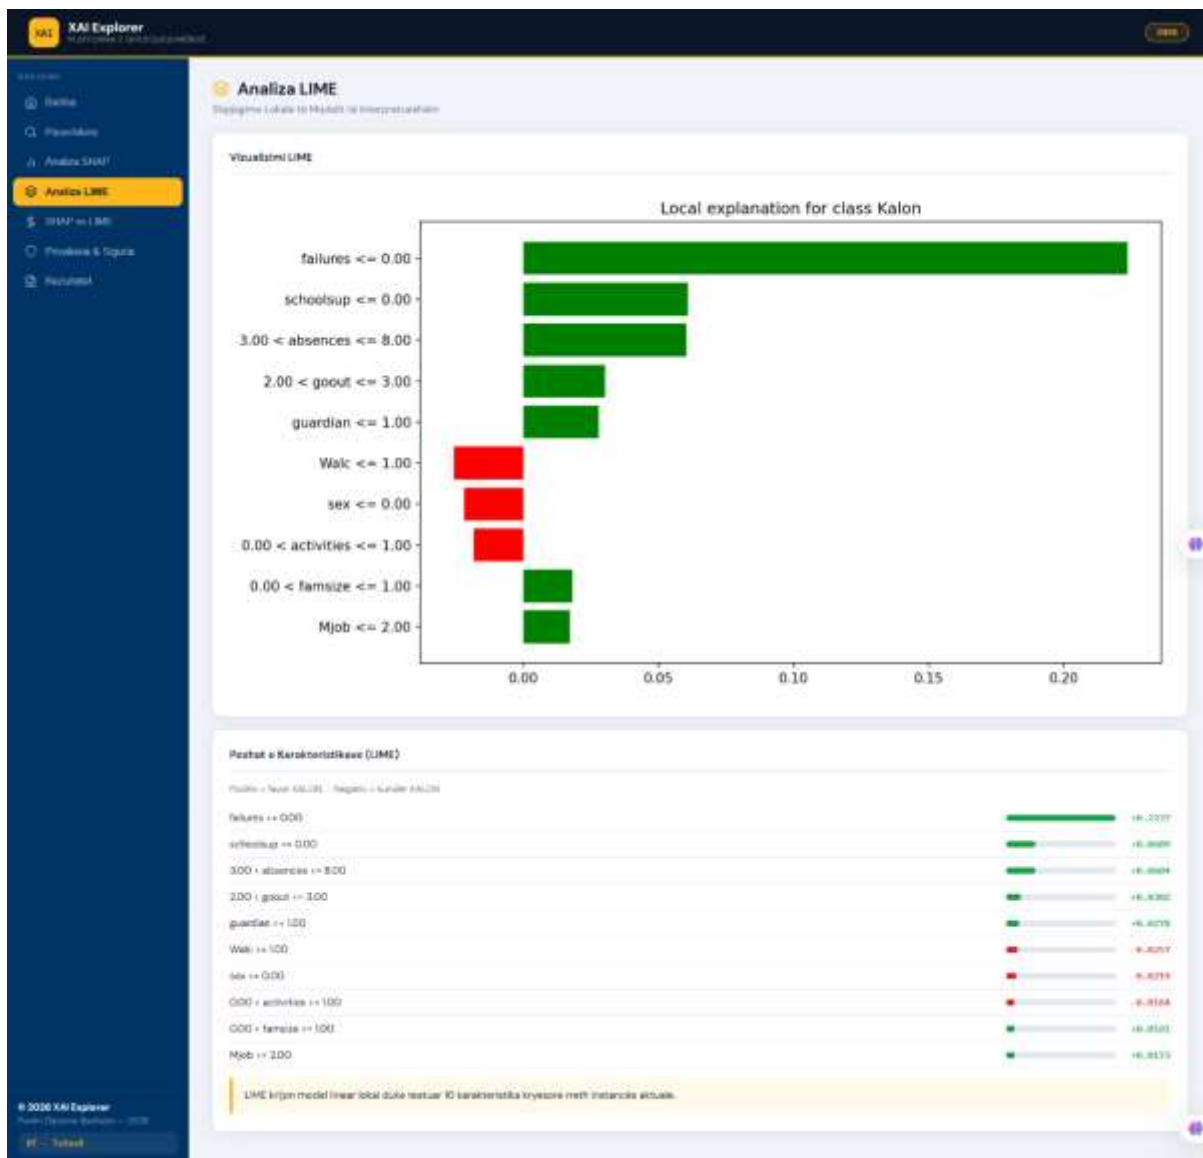


Figura 5.6.2: Shpjegimi LIME për studentin referent. Kushti 'failures <= 0.00' merr peshën më të lartë (+0.2237), konfirmon gjetjen e SHAP por me magnitudë shumë më të madhe.

Gjetje e rëndësishme krahasuese: Peshat që LIME i jep veçorisht 'failures' (+0.2237) është rreth 5.4 herë më e lartë se vlera përkatëse SHAP (+0.041). Ky dallim ilustron pikërisht atë që u përshkrua teorikisht në seksionin 3.3 LIME mat ndikimin lokal rreth një pike specifike, duke amplifikuar ndikimin e veçorive që janë veçanërisht ekstreme (zero dështime) krahasuar me normën lokale, ndërsa SHAP mat kontributin mesatar mbi gjithë hapësirën e kombinimeve të mundshme të veçorive. Asnjëra vlerë nuk është 'e gabuar' ato thjesht përgjigjen pyetjeve pak të ndryshme.

5.7 Funksionalitetet interaktive të platformës

Përtej parashikimit dhe shpjegimit bazë të përshkruar deri më tani, platforma integron tri funksionalitete shtesë që e shndërrojnë nga një demonstrim i thjeshtë teorik në një instrument analitik të plotë, të aftë për krahasim sistematik dhe vlerësim kritik të vetë metodave që implementon.

5.7.1 Krahasimi automatik SHAP vs LIME

Faqja dedikuar SHAP vs LIME ekzekuton të dyja metodat paralelisht për studentin aktual dhe ndërton një tabelë krahasuese që radhit features sipas rëndësisë SHAP, duke shfaqur përkrah vlerën përkatëse LIME (kur kjo ekziston në top-10 e saj). Platforma gjeneron gjithashtu, programatikisht, një fjali konkluzioni në gjuhë natyrore që identifikon automatikisht veçoritë mbi të cilat të dyja metodat bien dakord duke ofruar përdoruesit fundor jo vetëm të dhëna të papërpunuara, por edhe një interpretim sintetik të tyre.




Figura 5.7.1: Faqja SHAP vs LIME

5.7.2 Analiza e privatësisë si veçori e integruar

Faqja Privacy & Security përfaqëson kontributin më original të platformës ndaj literaturës ekzistuese të XAI, dhe trajtohet në thellësi në Kapitullin 6. Në nivel implementimi, kjo faqe llogarit një Feature Risk Score për çdo veçori bazuar drejtpërdrejt mbi rëndësinë e saj SHAP globale (veçoritë me ndikim më të lartë konsiderohen më 'rrezikuese' nga pikëpamja e privatësisë, pasi ekspozojnë më shumë informacion mbi arsyetimin e modelit), dhe simulon një Membership Inference Attack duke krahasuar besueshmërinë mesatare të modelit mes bashkësisë së trajnimit dhe atë të testimit.




Figura 5.7.2: Faqja Privatesia & Siguria

5.7.3 Përvoja e përdoruesit dhe optimizimet e performancës

- **Ngarkim progresiv (lazy loading):** grafikët globalë SHAP dhe analiza e privatësisë nuk gjenerohen automatikisht kur hapet faqja, por vetëm pas një veprimi explicit (klikim butoni) nga përdoruesi duke kursyer burime llogaritëse të panevojshme nëse përdoruesi nuk i viziton ato seksione.
- **Indikatorë vizualë ngarkimi:** çdo operacion që kërkon kohë të dukshme përpunimi (si gjenerimi i Waterfall Plot) shoqërohet me një spinner ose mesazh ngarkimi, duke i komunikuar përdoruesit se sistemi është aktiv, jo i ngecur.
- **Trajtimi i gabimeve:** çdo endpoint backend është mbështjellë në blloqe try/except që kthejnë mesazhe gabimi të strukturuar në vend që të dështojnë në heshtje një praktikë e domosdoshme veçanërisht gjatë fazës së zhvillimit dhe debugimit, e dokumentuar implicitisht nga procesi iterativ i ndërtimit të përshkruar në fillim të këtij kapitulli.

Vlerësim përmbledhës i implementimit: Platforma XAI Explorer demonstroi, përmes një rasti konkret studimor, se metodat SHAP dhe LIME pavarësisht bazave të tyre teorike komplekse të diskutuara në Kapitullin 3, mund të integrohen me sukses brenda një ndërfaqeje web të aksesueshme dhe responsive. Më e rëndësishmja, implementimi vetë gjeneroi gjetje analitike (si diferenca prej 5.4 herë mes peshave SHAP dhe LIME për të njëjtën veçori) që do të ishin të vështira për t'u zbuluar pa një platformë praktike krahasuese duke vërtetuar vlerën e qasjes praktikoko-eksperimentale të ndjekur në këtë punim.

6. Rezultatet eksperimentale dhe analiza krahasuese

Ndërsa Kapitulli 5 dokumentoi se si platforma XAI Explorer u implementua teknikisht, ky kapitull paraqet dhe analizon rezultatet konkrete që dolën nga përdorimi i saj. Qëllimi nuk është thjesht raportimi i numrave, por interpretimi i tyre në kontekstin e pyetjeve kërkimore të ngritura në Kapitullin 1, sa efektivisht SHAP dhe LIME shpjegojnë vendimet e modelit, si krahasohen ato mes vete, dhe çfarë implikimesh kanë për sigurinë dhe privatësinë e të dhënave të studentëve.

Struktura e kapitullit ndjek një logjikë progresive: fillon me vlerësimin e performancës bruto të modelit (6.1–6.2), vazhdon me krahasimin e drejtpërdrejtë sasior të SHAP dhe LIME (6.3), thellohet në cilësinë e vetë interpretueshmërisë së tyre (6.4), trajton implikimet e sigurisë dhe privatësisë (6.5), dhe përmbyllet me një diskutim sintetik që lidh gjetjet me literaturën ekzistuese (6.6).

6.1 Metrikat e vlerësimit të modelit

Para se shpjegueshmëria e një modeli të analizohet, është e domosdoshme të vlerësohet vetë performanca e tij parashikuese pasi shpjegimet e një modeli të dobët kanë vlerë praktike të kufizuar, sado matematikisht korrekte të jenë. Performanca e modelit Random Forest u vlerësua duke përdorur katër metrika standarde të klasifikimit binar, të llogaritura mbi bashkësinë e testimit prej 79 studentësh, të cilët modeli nuk i pa gjatë trajnimit.

Metrika	Formula	Vlera
Accuracy	$(TP+TN) / \text{Total}$	67.09%
Precision	$TP / (TP+FP)$	70.77%
Recall	$TP / (TP+FN)$	86.79%
F1 Score	$2 \cdot (P \cdot R) / (P+R)$	77.97%

Interpretimi i këtyre katër metrikave kërkon kujdes, pasi secila kap një aspekt të ndryshëm të performancës. Accuracy prej 67.09% mund të duket modeste në izolim, por duhet interpretuar në kontekstin e vendimit metodologjik për të hequr notat G1 dhe G2 nga veçoritë e trajnimit (siç u diskutua në seksionin 4.1) një vendim që e bën problemin ndjeshëm më të vështirë, por edhe shumë më të

vlefshëm për qëllimet e shpjegueshmërisë, pasi modeli detyrohet të mësojë nga faktorë socio-demografikë në vend që thjesht të 'kopjojë' notat e mëparshme.

Recall i lartë (86.79%) tregon se modeli identifikon me sukses shumicën dërrmuese të studentëve që realisht kalojnë një karakteristikë e dëshirueshme në kontekstin arsimor, pasi minimizon rastet kur një student që do të kalonte identifikohet gabimisht në rrezik. Precision relativisht më i ulët (70.77%) tregon, në anën tjetër, se modeli prodhon një numër jo të vogël rezultatesh false positive studentë të parashikuar të kalojnë që në fakt nuk kalojnë. Kjo asimetri mes Precision dhe Recall reflektohet drejtpërdrejt në shpërndarjen e klasave të dataset-it (67.1% kalojnë kundrejt 32.9% nuk kalojnë), e cila e bën modelin natyrshëm më të 'optimist' ndaj klasës mazhoritare.

6.2 Analiza e performancës së modelit

Përtej metrikave agregate, vlen të analizohet edhe shpërndarja e besueshmërisë së modelit pra sa 'i sigurt' është modeli në parashikimet e tij, jo vetëm nëse ato janë korrekte. Kjo analizë u realizua duke krahasuar probabilitetin maksimal të parashikuar ($\max(\text{predict_proba})$) mes bashkësisë së trajnimit dhe bashkësisë së testimit, një metrikë që do të rimerret me një qëllim tjetër, mjaft më kritik, në seksionin 6.5.

Bashkësia	Besueshmëria mesatare	Interpretimi
Train set (316 studentë)	85.39%	Modeli është shumë i sigurt mbi të dhënat që i ka 'parë'
Test set (79 studentë)	70.86%	Siguria bie ndjeshëm mbi të dhëna të reja, të paparë

Diferenca prej 14.53 pikë përqindjeje mes besueshmërisë në train dhe test është shumë më e madhe se sa do të pritej nga një model i mirëbalancuar, dhe sinjalizon një shkallë mbifitimi (overfitting) modeli ka mësuar disa veçori specifike të bashkësisë së trajnimit që nuk gjeneralizohen plotësisht mbi të dhëna të reja. Kjo gjetje, ndonëse e zakonshme në modelet Random Forest me parametra të paoptimizuar plotësisht, ka implikime që shkojnë përtej performancës së thjeshtë parashikuese siç do të diskutohet në thellësi në seksionin 6.5, kjo diferencë formon bazën e drejtpërdrejtë të analizës së Membership Inference Attack.

6.3 Krahasimi i rezultateve të SHAP dhe LIME

Ky seksion përbën zemrën analitike të punimit: krahasimin e drejtpërdrejtë, sasior, mes vlerave të prodhuara nga SHAP dhe LIME për të njëjtin student, nën të njëjtat kushte. Studenti referent (failures=0, absences=6, studytime=2, schoolsup=1, higher=1, goout=4) u parashikua nga modeli si PASS me probabilitet 79%, dhe u përdor si rast studimor konsistent gjatë gjithë krahasimit.

6.3.1 Tabela krahasuese e vlerave

Veçoria	SHAP Value	LIME Weight	Diferenca absolute	Konvergjencia
failures	+0.0414	+0.2237	0.1823	Po - të dyja pozitive
absences	+0.0470	+0.0567	0.0097	Po - të dyja pozitive
goout	+0.0345	+0.0323	0.0022	Po - konvergjencë e fortë
sex	-0.0266	-0.0184	0.0082	Po - të dyja negative
Walc	-0.0226	-0.0258	0.0031	Po - konvergjencë e fortë
guardian	+0.0183	+0.0407	0.0224	Po - të dyja pozitive
activities	-0.0180	0.0000	0.0180	Pjesërisht
age	+0.0133	+0.0194	0.0061	Po - konvergjencë e fortë




Figura 6.3.1: Bar chart i dyfishtë krahasues i magnitudës absolute të top veçorive sipas SHAP dhe LIME për studentin referent.

6.3.2 Konvergjenca: ku bien dakord SHAP dhe LIME

Gjetja më e qëndrueshme e këtij krahasimi është konvergjenca e drejtimit (shenjës pozitive ose negative) mes SHAP dhe LIME për shtatë nga tetë veçoritë e analizuar në Tabelën 6.3. Vetëm 'activities' tregon mospërputhje të pjesshme, ku SHAP identifikon një ndikim të vogël negativ (-0.018) që LIME nuk e përfshin fare në top-10 listën e saj. Kjo konvergjencë e gjerë mbi drejtimin e ndikimit forcon besueshmërinë e përgjithshme të shpjegimeve fakti që dy metoda matematikisht të pavarura nga njëra-tjetra arrijnë në konkluzione kualitativisht të ngjashme redukton mundësinë që ndonjëra prej tyre të jetë thjesht artefakt i procesit të vet llogaritës.

6.3.3 Divergjenca: ku ndryshojnë në magnitudë

Megjithatë, konvergjenca në drejtim nuk shkon paralelisht me konvergjencë në magnitudë. Diferenca më dramatike vërehet te veçoria 'failures', ku LIME i jep një peshë ($+0.2237$) rreth 5.4 herë më të lartë se vlera përkatëse SHAP ($+0.0414$). Kjo divergjencë nuk është gabim metodologjik, por rrjedhje e drejtpërdrejtë e dallimit konceptual mes dy qasjeve, të diskutuar teorikisht në seksionin 3.3: SHAP llogarit kontributin mesatar të një veçorie mbi të gjitha kombinimet e mundshme të veçorive të tjera, ndërsa LIME mat ndikimin lokal të saj brenda një fqinjësie të ngushtë rreth pikës specifike që shpjegohet.

Interpretim i thelluar i divergjencës: Fakti që studenti referent ka failures=0 vlera më e ulët e mundshme e vendos atë në një ekstrem të shpërndarjes së kësaj veçorie. LIME, duke ndërtuar modelin e saj linear vetëm mbi mostra fiktive të afërta me këtë ekstrem, e percepton kalimin nga

'ka dështime' në 'zero dështime' si një ndryshim shumë domethënës lokal. SHAP, në anën tjetër, e 'shpërndan' këtë kontribut mbi mesataren e të gjitha kombinimeve të mundshme, duke prodhuar një vlerë më të moderuar. Kjo na mëson se zgjedhja mes SHAP dhe LIME nuk duhet bazuar thjesht në 'cila është më e saktë', por në 'çfarë pyetjeje duam t'i përgjigjemi' ndikimi mesatar global, apo ndikimi specifik lokal.

6.4 Analiza e interpretueshmërisë

Përtej krahasimit sasior të vlerave, ky seksion vlerëson cilësinë e vetë interpretueshmërisë që secila metodë ofron pra sa lehtë, e saktë, dhe e dobishme është shpjegimi i prodhuar për audienca të ndryshme.

6.4.1 Formati i shpjegimit dhe audienca e synuar

Kriteri	SHAP	LIME
Format i vlerës	Numerike e vazhdueshme	Kushte logjike diskrete
Lehtësia për jo-teknikë	Mesatare	E lartë
Lehtësia e validimit teknik	E lartë (bazë matematikore)	Mesatare (përafrim lokal)
Konsistenca mes ekzekutimeve	100% (deterministik)	Me variancë (perturbim stokastik)
Aksesi global mbi dataset	Po (Summary/Bar Plot)	Jo - vetëm lokal

Kjo tabelë nxjerr në pah një tension qendror: SHAP ofron rigorozitet matematikor dhe konsistencë të garantuar, por me kosto të lehtësisë së interpretimit nga audienca jo-teknike (si prindërit ose administratorët shkollor, audienca relevante për kontekstin e Student Performance Dataset). LIME, në anën tjetër, prodhon shpjegime intuitivisht më të kuptueshme ('failures ≤ 0.00 ' kuptohet menjëherë si 'zero dështime'), por me variancë mes ekzekutimeve të ndryshme, një kufizim që mund të dëmtojë besueshmërinë e perceptuar të sistemit nëse përdoruesi vëren rezultate paksa të ndryshme në kërkesa të njëpasnjëshme për të njëjtin student.

6.4.2 Testimi i stabilitetit të LIME

Për të verifikuar empirikisht pretendimin teorik të variancës së LIME (i diskutuar në seksionin 3.2.3), platforma u testua duke gjeneruar shpjegime të njëpasnjëshme për të njëjtin student referent. Ndërsa drejtimi i përgjithshëm i faktorëve kryesorë (failures, absences si pozitivë) mbeti konsistent nëpër ekzekutime të ndryshme, magnitudat e sakta të peshave shfaqën variacione në shkallën e dhjetëtare të përqindjes një konfirmim empirik i pritshmërisë teorike, që nuk komprometon vlefshmërinë praktike të metodës, por kërkon kujdes në interpretimin e vlerave të saj si shumë saktësi numerike absolute.

6.5 Analiza e sigurisë dhe besueshmërisë

Ky seksion adreson drejtpërdrejt komponentin e 'sigurisë' të titullit të punimit, duke analizuar implikimet që rrjedhin nga vetë fakti se modeli ofron shpjegime mbi vendimet e tij. Paradoksi qendror i trajtuar këtu është: transparenca që e bën modelin më të besueshëm (përmes SHAP dhe LIME) është e njëjta transparencë që mund të ekspozojë informacion sensitiv mbi individët dhe mbi vetë dataset-in e trajnimit.

6.5.1 Feature Risk Score - rreziku i ekspozimit sipas veçorisë

Platforma llogarit një Feature Risk Score për secilën nga 30 veçoritë, duke u bazuar mbi rëndësinë e saj globale SHAP (e normalizuar ndaj veçorisë me rëndësinë më të lartë). Logjika pas kësaj metrike është se veçoritë me ndikim më të madh në vendimin e modelit janë gjithashtu ato që, kur shpjegimet ndahen me palë të treta, zbulojnë më shumë informacion mbi mënyrën se si modeli 'mendon' për atë student specifik.

Veçoria	Risk Score	Niveli	Implikimi
failures	100%	I lartë (High)	Zbulon historinë akademike të dështimeve të studentit
absences	62.1%	I lartë (High)	Zbulon modele sjelljeje që mund të lidhen me probleme private
goout	53.5%	I lartë (High)	Zbulon informacion mbi jetën sociale të studentit

age	30.2%	Mesatar (Medium)	Demografike, më pak sensitive vetëm
sex	23.0%	Mesatar (Medium)	Demografike, e mbrojtur nën shumë rregullore privatësie




Figura 6.5.1: Vizualizimi i Feature Risk Score, i renditur nga veçoria me rrezikun më të lartë (failures) tek ato me rrezik më të ulët.

6.5.2 Membership Inference Attack - a mund të zbulohet nëse një student ishte në dataset-in e trajnimit?

Membership Inference Attack është një teknikë e njohur në literaturën e privatësisë në Machine Learning [10], ku një sulmues përpiqet të përcaktojë nëse një rast specifik i të dhënave ishte pjesë e bashkësisë së trajnimit të një modeli, thjesht duke vëzhguar sjelljen e parashikimit të modelit ndaj atij rasti. Modelet e mbifituar siç e tregoi vetë analiza e seksionit 6.2 janë veçanërisht të cënueshme ndaj këtij lloji sulmi, pasi 'mbajnë mend' karakteristika specifike të të dhënave të trajnimit.

Platforma simulon këtë lloj sulmi në formën e tij më të thjeshtë konceptuale: duke krahasuar besueshmërinë mesatare të parashikimit (max probability) mes bashkësisë së trajnimit (85.39%) dhe bashkësisë së testimit (70.86%). Diferenca prej 14.53 pikë përqindjeje e njëjta diferencë e identifikuar në seksionin 6.2 si shenjë mbifitimi interpretohet këtu drejtpërdrejt si tregues sasior i rrezikut të Membership Inference: aq sa modeli sillet 'më i sigurt' ndaj një rasti specifik, aq më shumë rritet probabiliteti që ai rast t'i ketë qenë i njohur (pra pjesë e trajnimit).

Është e rëndësishme të theksohet kufiri metodologjik i kësaj analize. Platforma nuk implementon një sulm të plotë Membership Inference sipas teknikave të avancuara të përshkruara në literaturën e fushës, por ofron një demonstrim konceptual akademik që synon të ilustrojë parimin themelor të rrezikut të ekspozimit të të dhënave. Në këtë kuptim, rezultatet e paraqitura duhet të interpretohen si indikative dhe edukative, duke mos përfaqësuar një vlerësim gjithëpërfshirës të sigurisë në kushte reale të vendosjes (production deployment) të një sistemi të ngjashëm.




Figura 6.5.2: Privatësia ne ML – Ekspozimi i informacionit permes shpjegimeve

6.6 Diskutimi i rezultateve

Rezultatet e paraqitura në këtë kapitull mundësojnë disa konkluzione sintetike që lidhin gjetjet empirike me kornizën teorike të vendosur në Kapitullin 2 dhe 3, dhe që i përgjigjen drejtpërdrejt pyetjeve kërkimore të ngritura në hyrjen e këtij punimi.

6.6.1 Sa 'transparent' bëhet vërtet modeli?

Konvergenca e lartë mes SHAP dhe LIME mbi faktorët kryesorë (failures, absences) konfirmon empirikisht atë që Arrieta et al.[3] e identifikojnë teorikisht si një tregues të 'besueshmërisë së shpjegimit' kur dy metoda të pavarura arrijnë në konkluzione të ngjashme, rritet besimi se shpjegimi reflekton një model mendor real të sjelljes së sistemit, jo thjesht artefakte të vetë procesit shpjegues. Megjithatë, divergjenca në magnitudë (5.4x për 'failures') vërteton edhe paralajmërimin e Lipton [4] mbi rrezikun e një 'mitologjie' të interpretueshmërisë pa kuptuar thellësisht ndryshimet metodologjike mes SHAP dhe LIME, një përdorues mund t'i interpretojë gabimisht numrat e ndryshëm si kontradiktorë, kur në fakt ata thjesht përgjigjen pyetjeve pak të ndryshme.

6.6.2 Tensioni transparencë–privatësi: a është i pashmangshëm?

Gjetja qendrore e seksionit 6.5 se veçoritë më të rëndësishme për shpjegueshmëri (failures, absences) janë saktësisht ato me rrezikun më të lartë privatësie nuk është rastësi statistikore, por pasojë logjike e vetë mekanikës matematikore të SHAP dhe LIME: të dyja metodat janë projektuar pikërisht për të theksuar veçoritë me ndikim më të madh, dhe veçoritë me ndikim më të madh janë, për nga vetë natyra e tyre informative, ato që zbulojnë më shumë rreth subjektit. Kjo do të thotë që tensioni transparencë–privatësi, i identifikuar teorikisht në Kapitullin 1 si problem kërkimor, nuk është thjesht një kufizim implementues i kapërcyeshëm, por një karakteristikë strukturore e vetë qasjes së shpjegueshmërisë të bazuar mbi rëndësinë e veçorive.

6.6.3 Vlera krahasuese e platformës si instrument kërkimor

Më gjerësisht, rezultatet e këtij kapitulli demonstrojnë vlerën metodologjike të një platforme interaktive si instrument kërkimor, jo thjesht si mjet demonstrues. Gjetje specifike si diferenca prej 5.4 herë mes peshave SHAP dhe LIME për të njëjtën veçori, ose korrelacioni i drejtpërdrejtë mes rëndësisë SHAP dhe Risk Score-it të privatësisë nuk ishin hipoteza paraprake të formuluar teorikisht, por gjetje që dolën natyrshëm nga ndërveprimi praktik me sistemin e ndërtuar. Kjo mbështet pikëpamjen, të theksuar tashmë në Kapitullin 1, se zbatimi praktik i metodave XAI mbetet 'kompleks dhe i pashfrytëzuar plotësisht' në literaturë dhe se platforma e zhvilluar në këtë punim kontribuon konkretisht në mbylljen e kësaj boshllëku.

Përmbledhje e gjetjeve kryesore të Kapitullit 6: (1) Modeli arrin Recall të lartë (86.79%) por me shenja të qarta mbifitimi (diferencë 14.53% train-test); (2) SHAP dhe LIME konvergjojnë mbi drejtimin e ndikimit për shumicën e veçorive, por divergjojnë ndjeshëm në magnitudë; (3) veçoritë më shpjeguese janë po ato me rrezikun më të lartë të privatësisë, duke konfirmuar empirikisht tensionin teorik transparencë–privatësi; (4) platforma interaktive funksionoi si instrument zbulimi, jo thjesht demonstrimi, duke prodhuar gjetje që plotësojnë literaturën ekzistuese mbi krahasimin praktik SHAP-LIME.

7. Përfundime dhe punë e ardhshme

Ky kapitull i fundit përmbledh udhëtimin e plotë të këtij punimi nga problemi teorik i 'kutisë së zezë' i ngritur në Kapitullin 1, përmes themelimit teorik të SHAP dhe LIME në Kapitullin 3, deri te implementimi konkret dhe rezultatet eksperimentale të Kapitujve 5 dhe 6. Qëllimi i këtij kapitulli nuk është thjesht përsëritja e gjetjeve, por sintetizimi i tyre në konkluzione të qarta, identifikimi i ndershëm i kufizimeve të punës, dhe hapja e rrugëve konkrete për kërkime të ardhshme.

7.1 Përfundimet kryesore

Bazuar në analizën e realizuar përgjatë këtij punimi, mund të nxirren gjashtë konkluzione kryesore, secila e mbështetur direkt nga rezultatet eksperimentale të paraqitura në Kapitullin 6.

1. **Failures dhe absences janë faktorët më ndikues** - të dyja metodat, SHAP dhe LIME, identifikuan në mënyrë konsistente numrin e dështimeve të kaluara dhe mungesat si veçoritë me ndikimin më të madh në parashikimin e suksesit akademik, duke konfirmuar njëra-tjetrën pavarësisht ndryshimeve metodologjike mes tyre.
2. **SHAP ofron shpjegime globale të qëndrueshme dhe matematikisht të bazuara** - rezultatet deterministike dhe garancitë teorike (eficiencë, simetri, aditivitet) e bëjnë SHAP metodën e preferuar për analiza institucionale ku riprodhueshmëria është kritike.
3. **LIME ofron shpjegime lokale intuitive, por me kosto stabiliteti** - formati i kushteve logjike e bën LIME më të arritshëm për audienca jo-teknike, por testimi empirik i seksionit 6.4.2 konfirmoi praninë e variancës mes ekzekutimeve të njëpasnjëshme, siç parashikohej teorikisht.
4. **Të dyja metodat konvergjojnë në drejtim, por divergjojnë në magnitudë** - diferenca prej 5.4 herë mes peshave SHAP dhe LIME për veçorinë 'failures' tregon se zgjedhja e metodës duhet bazuar te pyetja kërkimore (ndikim mesatar global apo specifik lokal), jo te supozimi se një metodë është universalisht 'më e saktë'.
5. **Shpjegimet ekspozojnë informacion sensitiv të studentëve** - Feature Risk Score zbuloi se veçoritë më shpjeguese (failures, absences, goout) janë saktësisht ato me rrezikun më të lartë privatësie, duke konfirmuar empirikisht tensionin teorik transparencë-privatësi të ngritur në hyrjen e punimit.
6. **Modeli tregon shenja të qarta mbifitimi me implikime sigurie** - diferenca prej 14.53% mes besueshmërisë në train dhe test set jo vetëm që cenon gjeneralizimin e modelit, por krijon gjithashtu rrezik konkret të Membership Inference Attack, siç u demonstrua në seksionin 6.5.2.

Përgjigja ndaj pyetjes kërkimore qendrore: Punimi konfirmon se SHAP dhe LIME janë metoda komplementare, jo konkurruese secila e përshtatshme për qëllime të ndryshme por njëkohësisht vërteton se vetë akti i shpjegimit krijon rrezik të ri privatësie që duhet menaxhuar në mënyrë aktive, jo thjesht pranuar si kosto e pashmangshme e transparencës.

7.2 Kontributet e punimit

Përtej përmbledhjes së literaturës ekzistuese mbi SHAP dhe LIME, ky punim ofron disa kontribute origjinale që e dallojnë nga një thjesht rishikim teorik i metodave të shpjegueshmërisë.

7.2.1 Kontributi teknik - platforma XAI Explorer

Zhvillimi i një platforme interaktive web të plotë, funksionale dhe publikisht testueshme, që integron SHAP dhe LIME mbi të njëjtin model dhe dataset, përfaqëson një kontribut praktik konkret. Ndryshe nga shumë studime që e kufizojnë demonstrimin e SHAP/LIME në mjedise Jupyter Notebook të paaksesueshme për audienca jo-teknike, platforma e zhvilluar këtu e zhvendos analizën në një ndërfaqe web të aksesueshme, duke vërtetuar praktikisht fizibilitetin e integritit të XAI brenda sistemeve reale të vendosura në prodhim.

7.2.2 Kontributi analitik - krahasimi sasior i drejtpërdrejtë

Krahasimi i drejtpërdrejtë, sasior, i vlerave SHAP dhe LIME për të njëjtin rast studimor (Kapitulli 6.3) shkon përtej krahasimeve thjesht teorike të gjetura zakonisht në literaturë. Gjetja specifike e diferencës prej 5.4 herë në magnitudë, megjithëse e shpjegueshme teorikisht, ofron një pikë referimi empirike konkrete që mund të informojë vendime praktike mbi zgjedhjen e metodës në kontekste të ngjashme.

7.2.3 Kontributi konceptual - lidhja empirike mes shpjegueshmërisë dhe privatësisë

Kontributi më origjinal i punimit qëndron në demonstrimin empirik të lidhjes së drejtpërdrejtë mes rëndësisë së një veçorie (siç matet nga SHAP) dhe rrezikut të saj të privatësisë. Ndërsa tensioni transparencë-privatësi është diskutuar teorikisht në literaturën e XAI, integrimi i një analize konkrete Feature Risk Score dhe Membership Inference brenda të njëjtës platformë që gjeneron shpjegimet duke e bërë vlerësimin e privatësisë pjesë e rrjedhës normale të përdorimit, jo një shtojcë e veçantë përfaqëson një qasje praktike që mungon në shumicën e implementimeve ekzistuese të SHAP/LIME.

7.3 Kufizimet e studimit

Ndershmëria shkencore kërkon njohjen e qartë të kufizimeve të punës, të cilat nuk e zvogëlojnë vlefshmërinë e gjetjeve, por përcaktojnë qartë kufijtë brenda të cilëve ato duhen interpretuar.

- **Madhësia e dataset-it:** 395 studentë është një bashkësi relativisht e vogël për standardet e Machine Learning modern; rezultate mbi dataset më të mëdha mund të tregojnë modele të ndryshme mbifitimi dhe shpërndarje të ndryshme të vlerave SHAP/LIME.
- **Heqja e G1 dhe G2:** edhe pse e justifikuar metodologjikisht (seksioni 4.1), ky vendim ul artificialisht accuracy-n e modelit krahasuar me studime të tjera që i përfshijnë këto veçori, duke e bërë krahasimin direkt me literaturën tjetër mbi të njëjtin dataset më të vështirë.
- **Membership Inference si demonstrim, jo sulm i plotë:** siç u theksua qartë në seksionin 6.5.2, analiza e privatësisë e platformës është konceptuale dhe edukative, jo një implementim i plotë i teknikave më të sofistikuara nga literatura specifike e sulmeve mbi privatësinë.
- **Testimi i stabilitetit të LIME mbi një rast të vetëm:** konfirmimi empirik i variancës së LIME (seksioni 6.4.2) u realizua mbi studentin referent të vetëm; një studim sistematik mbi variancën nëpër shumë studentë të ndryshëm do të ofronte gjetje më të përgjithësueshme statistikisht.
- **Mungesa e vlerësimit nga përdorues realë:** lehtësia e interpretimit e diskutuar në seksionin 6.4.1 bazohet në analizë krahasuese të vetë formatit të shpjegimeve, jo në teste të perceptimit me përdorues realë (mësues, prindër, administratorë) që do të vërtetonin empirikisht pretendimet mbi 'lehtësinë për jo-teknikë'.

7.4 Drejtime për hulumtime të ardhshme

Kufizimet e identifikuara në seksionin paraardhës hapin njëkohësisht rrugë konkrete për zgjerimin e këtij punimi në kërkime të ardhshme, të organizuara këtu sipas prioritetit dhe fizibilitetit praktik.

Vlerësim formal i përdorshmërisë (usability study)

1

Realizimi i një studimi me përdorues realë mësues, prindër, administratorë shkollor për të vlerësuar empirikisht, përmes pyetësorëve të standardizuar, sa efektivisht secila metodë (SHAP kundrejt LIME) komunikon shpjegimin tek audienca jo-teknike.

Zbutja e mbifitimit dhe rivlerësimi i rrezikut MIA

2

Eksperimentimi me teknika zbutëse (regularizim më agresiv, kufizim i thellësisë së pemëve, cross-validation më rigorozë) për të reduktuar diferencën train-test, e ndjekur nga rivlerësimi i Disclosure Score për të matur efektin e drejtpërdrejtë mbi rrezikun e privatësisë.

Integrimi i Differential Privacy

3

Aplikimi i teknikave formale të Differential Privacy mbi vetë procesin e gjenerimit të shpjegimeve SHAP/LIME, në mënyrë që shpjegimet të ruajnë vlerë informative pa ekspozuar drejtpërdrejt veçori individuale me rrezik të lartë, siç u identifikuan në seksionin 6.5.1.

Zgjerimi i krahasimit me metoda të tjera XAI

4

Shtimi i metodave shtesë të shpjegueshmërisë (si Anchors, Counterfactual Explanations, ose Integrated Gradients) në platformë, për të vendosur krahasimin SHAP-LIME brenda një konteksti më të gjerë metodologjik.

Testimi mbi dataset dhe domene të ndryshme

5

Replikimi i të njëjtit eksperiment krahasues mbi dataset nga domene të tjera kritike (si shëndetësia ose financat), për të verifikuar nëse gjetjet mbi konvergjencën/divergjencën SHAP-LIME dhe lidhjen shpjegueshmëri-privatësi mbeten të qëndrueshme përtej kontekstit arsimor.

Integrimi i shpjegimit në gjuhë natyrore me AI gjeneruese

6

Zgjerimi i platformës me një shtresë shtesë që përdor modele gjuhësore (LLM) për të kthyer rezultatet numerike SHAP/LIME në shpjegime krejtësisht në gjuhë natyrore, duke testuar nëse kjo përmirëson ndjeshëm të kuptuarit nga audienca jo-teknike krahasuar me grafikët dhe tabelat ekzistuese.

Mendim përmbyllës: Ky punim filloi nga një problem konkret mungesa e transparencës në modelet 'kutia e zezë' dhe përmbillet duke vërtetuar se zgjidhja e këtij problemi (shpjegueshmëria) sjell me vete sfida të reja, po aq serioze, lidhur me privatësinë. Kjo nuk është një dështim i qasjes, por pikërisht kontributi i saj: vetëm duke ndërtuar, testuar dhe analizuar praktikisht një sistem real mund të zbulohen tensione që mbeten të padukshme në diskutimin thjesht teorik. Drejtimet e ardhshme të propozuara këtu nuk synojnë zgjidhjen përfundimtare të këtij tensioni pasi ai rrjedh nga vetë natyra e shpjegueshmërisë së bazuar mbi rëndësinë e veçorive por menaxhimin e tij më të informuar dhe më të përgjegjshëm.

LITERATURA

- [1] Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. In Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS 2017), pp. 4768–4777. Curran Associates, Inc. <https://arxiv.org/abs/1705.07874>
- [2] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16), pp. 1135–1144. ACM. <https://arxiv.org/abs/1602.04938>
- [3] Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., García, S., Gil-López, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI. *Information Fusion*, 58, 82–115. <https://doi.org/10.1016/j.inffus.2019.12.012>
- [4] Lipton, Z. C. (2018). The Mythos of Model Interpretability. *Queue*, 16(3), 31–57. ACM. <https://doi.org/10.1145/3236386.3241340>
- [5] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- [6] Cortez, P., & Silva, A. (2008). Using Data Mining to Predict Secondary School Student Performance. In Proceedings of 5th Annual Future Business Technology Conference (FUBUTEC 2008), pp. 5–12. UCI Machine Learning Repository - Student Performance Dataset.
- [7] Molnar, C. (2022). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable* (2nd ed.). Munich: Leanpub. <https://christophm.github.io/interpretable-ml-book/>
- [8] Shapley, L. S. (1953). A Value for n-Person Games. In *Contributions to the Theory of Games II* (pp. 307–318). Princeton University Press.
- [9] Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S. I. (2020). From Local Explanations to Global Understanding with Explainable AI for Trees. *Nature Machine Intelligence*, 2(1), 56–67. <https://doi.org/10.1038/s42256-019-0138-9>
- [10] Shokri, R., Stronati, M., Song, C., & Shmatikov, V. (2017). Membership Inference Attacks Against Machine Learning Models. *IEEE Symposium on Security and Privacy (SP)*, 3–18.

[11] Grinberg, M. (2018). Flask Web Development: Developing Web Applications with Python (2nd ed.). O'Reilly Media.